

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

KHOA KHOA HỌC MÁY TÍNH

Nguyễn Phước Thọ

ĐỒ ÁN TỐT NGHIỆP

**Xây dựng hệ thống dự báo xu hướng biến động giá cổ phiếu dựa trên
phân tích cảm xúc tin tức tài chính bằng mô hình Transformer và
chuỗi thời gian**

*Building a stock price movement forecasting system based on financial news
sentiment analysis using Transformer and time-series models*

CỬ NHÂN NGÀNH TRÍ TUỆ NHÂN TẠO

TP. HỒ CHÍ MINH, 2026

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

KHOA KHOA HỌC MÁY TÍNH

Nguyễn Phước Thọ – 25410139

ĐỒ ÁN TỐT NGHIỆP

**Xây dựng hệ thống dự báo xu hướng biến động giá cổ phiếu dựa trên
phân tích cảm xúc tin tức tài chính bằng mô hình Transformer và
chuỗi thời gian**

*Building a stock price movement forecasting system based on financial news
sentiment analysis using Transformer and time-series models*

CỬ NHÂN NGÀNH TRÍ TUỆ NHÂN TẠO

GIẢNG VIÊN HƯỚNG DẪN

TS. Đặng Văn Thìn

TP. HỒ CHÍ MINH, 2026

THÔNG TIN HỘI ĐỒNG CHẤM ĐỒ ÁN TỐT NGHIỆP

Hội đồng chấm Đồ án tốt nghiệp, thành lập theo Quyết định số _____ ngày _____ của Hiệu trưởng Trường Đại học Công nghệ Thông tin.

- 1. _____ – Chủ tịch.
- 2. _____ – Thư ký.
- 3. _____ – Ủy viên.

LỜI CẢM ƠN

Em xin gửi lời cảm ơn chân thành đến giảng viên hướng dẫn TS. Đặng Văn Thìn đã tận tình định hướng và góp ý trong suốt quá trình thực hiện đồ án.

Em cũng xin cảm ơn quý thầy cô Khoa Khoa học Máy tính, Trường Đại học Công nghệ Thông tin đã trang bị cho em nền tảng kiến thức để hoàn thành đồ án này.

TP. Hồ Chí Minh, 2026

Sinh viên thực hiện

Nguyễn Phước Thọ

Mục lục

Thông tin hội đồng chấm đồ án tốt nghiệp

Lời cảm ơn

Danh mục từ viết tắt

Tóm tắt đồ án	1
1 MỞ ĐẦU	2
1.1 Lý do chọn đề tài	2
1.1.1 Bối cảnh tiếng Việt và thị trường Việt Nam	2
1.1.2 Động cơ kết hợp hai loại dữ liệu	2
1.1.3 Vấn đề phương pháp cần giải quyết	3
1.1.4 Ý nghĩa của đề tài	3
1.2 Mục tiêu nghiên cứu	3
1.2.1 Câu hỏi nghiên cứu	4
1.2.2 Mục tiêu cụ thể	4
1.2.3 Nguyên tắc diễn giải kết quả	4
1.3 Đối tượng và phạm vi nghiên cứu	5
1.3.1 Đối tượng nghiên cứu	5
1.3.2 Phạm vi thị trường và mã cổ phiếu	5
1.3.3 Phạm vi thời gian và tần suất	5
1.3.4 Phạm vi bài toán và giới hạn	5
1.3.5 Đóng góp dự kiến	6
1.4 Cấu trúc đồ án	6
1.4.1 Chương 2, Tổng quan	6
1.4.2 Chương 3, Phương pháp	6
1.4.3 Chương 4, Kết quả thực nghiệm	6
1.4.4 Chương 5 và Chương 6	7
2 TỔNG QUAN	8
2.1 Phân tích cảm xúc tin tức tài chính	8
2.1.1 Từ mô hình ngôn ngữ tổng quát đến mô hình miền tài chính	8
2.1.2 Các công trình sentiment và chuyển động cổ phiếu quốc tế	8
2.1.3 Đặc thù của sentiment tài chính tiếng Việt	9
2.1.4 Đánh giá chất lượng nhãn và đầu ra sentiment	9
2.2 Dự báo xu hướng giá bằng mô hình chuỗi thời gian	10
2.2.1 Baseline chỉ giá và các mô hình cổ điển	10
2.2.2 LSTM cho phụ thuộc ngắn hạn và dài hạn	10
2.2.3 Transformer cho chuỗi thời gian	10
2.2.4 Dịch chuyển phân phối và quan hệ giữa các mã	11
2.3 Kết hợp tin tức và giá (multimodal)	11

2.3.1	Hợp nhất bằng điểm sentiment	11
2.3.2	Hợp nhất bằng embedding ngữ cảnh và sự kiện	11
2.3.3	Hợp nhất động và LLM	12
2.3.4	Các cơ chế fusion	12
2.3.5	Đánh giá multimodal và nguy cơ diễn giải quá mức	12
2.4	Khoảng trống nghiên cứu và định vị đề tài	13
2.4.1	Tổng hợp theo ba trụ	13
2.4.2	So sánh các hướng nghiên cứu	13
2.4.3	Định vị và giả thuyết kiểm chứng	13
2.4.4	Tiêu chí để tuyên bố đóng góp	14

3 PHƯƠNG PHÁP 15

3.1	Tổng quan kiến trúc hệ thống	15
3.1.1	Nguyên tắc thiết kế	15
3.1.2	Cơ sở lý thuyết của Transformer và self-attention	15
3.1.3	Cơ sở lý thuyết của PhoBERT	16
3.1.4	Cơ sở lý thuyết của LSTM	16
3.1.5	Cơ sở lý thuyết của Temporal Fusion Transformer	16
3.1.6	Luồng xử lý tổng thể	17
3.2	Thu thập và tiền xử lý dữ liệu	19
3.2.1	Phạm vi dữ liệu và nguồn thu thập	19
3.2.2	Kiểm tra chất lượng và provenance	19
3.2.3	Dữ liệu giá	19
3.2.4	Dữ liệu tin tức và ánh xạ theo phiên	19
3.2.5	Tiền xử lý văn bản tiếng Việt	20
3.2.6	Tạo tập sentiment và gán nhãn	20
3.3	Nhánh cảm xúc: tinh chỉnh PhoBERT	20
3.3.1	Thiết lập bài toán phân loại	20
3.3.2	Chia dữ liệu và huấn luyện	21
3.3.3	Đầu ra xác suất và tổng hợp theo mã, ngày	21
3.4	Nhánh giá và ghép đặc trưng	22
3.4.1	Đặc trưng kỹ thuật	22
3.4.2	Căn chỉnh hai nguồn dữ liệu	22
3.4.3	Gán nhãn xu hướng phiên kế tiếp	22
3.4.4	Hợp nhất bằng LSTM hai nhánh	22
3.5	Thang mô hình dự báo	23
3.5.1	Tầng baseline	23
3.5.2	Tầng mô hình cổ điển chỉ giá	23
3.5.3	Tầng LSTM chỉ giá	23
3.5.4	Tầng LSTM hai nhánh có sentiment	23
3.5.5	Tầng TFT mở rộng	24
3.5.6	Huấn luyện và kiểm soát độ phức tạp	24
3.6	Giao thức đánh giá chống rò rỉ	24
3.6.1	Walk-forward và holdout cuối	24

3.6.2	Kiểm soát điểm nhìn và các phép biến đổi	24
3.6.3	Các chỉ số đánh giá	25
3.6.4	Ablation và khoảng tin cậy	25
3.6.5	Phân tích độ bền và điều kiện phát huy tín hiệu	25
3.6.6	Giải thích mô hình	25
3.6.7	Tái lập và báo cáo	26
4	KẾT QUẢ THỰC NGHIỆM	27
4.1	Thiết lập thực nghiệm	27
4.1.1	Môi trường và cấu hình phần mềm	27
4.1.2	Thiết kế chia dữ liệu	27
4.1.3	Cấu hình huấn luyện và tiêu chí chọn mô hình	28
4.2	Thống kê dữ liệu	28
4.2.1	Quy mô corpus tin	28
4.2.2	Quy mô dữ liệu giá và phân bố nhãn	28
4.3	Kết quả phân loại cảm xúc	29
4.3.1	Chất lượng nhãn in-domain	29
4.3.2	Chỉ số mô hình sentiment	29
4.4	Kết quả dự báo xu hướng và ablation	30
4.4.1	Báo cáo chỉ số theo lớp	30
4.4.2	Đo phần đóng góp của sentiment	30
4.4.3	Kết quả TFT nếu được thực hiện	30
4.5	Bàn luận	31
4.5.1	Bàn luận theo câu hỏi nghiên cứu	31
4.5.2	Kiểm tra tính hợp lệ và độ ổn định	31
4.5.3	Giới hạn của thực nghiệm	31
5	KẾT LUẬN	32
5.1	Tóm tắt nội dung thực hiện	32
5.2	Đối chiếu với mục tiêu và câu hỏi nghiên cứu	32
5.3	Đóng góp và ý nghĩa	32
5.4	Giới hạn của đề án	33
5.5	Kết luận cuối cùng	33
6	HƯỚNG PHÁT TRIỂN	34
6.1	Củng cố dữ liệu và giao thức point-in-time	34
6.2	Cơ chế hợp nhất nâng cao	34
6.3	Mở rộng phạm vi thị trường và concept drift	35
6.4	Đánh giá giá trị kinh tế	35
6.5	Giải thích và kiểm tra độ bền	35
6.6	Mở rộng mô hình ngôn ngữ	36
6.7	Đóng gói và tái lập hệ thống	36
6.8	Lộ trình ưu tiên	36
	TÀI LIỆU THAM KHẢO	37

A	PHỤ LỤC	39
A.1	Hướng dẫn gán nhãn cảm xúc in-domain	39
A.2	Cấu hình tái lập	39
A.3	Mã nguồn	39

Danh sách hình vẽ

3.1 Kiến trúc tổng thể của pipeline dự báo xu hướng giá. 18

Danh sách bảng

2.1	So sánh các nhóm nghiên cứu liên quan với phạm vi đề tài.	13
3.1	Tóm tắt các quyết định thiết kế chính.	26
4.1	Thông tin thiết lập cần ghi nhận trong manifest.	27
4.2	Thống kê corpus tin tức sau các bước kiểm tra.	28
4.3	Thống kê dữ liệu giá và phân bố nhãn ba lớp.	29
4.4	Thông tin gán nhãn tập sentiment in-domain.	29
4.5	Kết quả phân loại sentiment trên tập test, số liệu để điền sau.	29
4.6	So sánh mô hình theo macro-F1, số liệu để điền sau.	30
4.7	Ablation có và không có sentiment, số liệu để điền sau.	30

DANH MỤC TỪ VIẾT TẮT

Từ viết tắt	Diễn giải
AUC	Area Under the Curve (diện tích dưới đường ROC)
BiLSTM	Bidirectional Long Short-Term Memory
CI	Confidence Interval (khoảng tin cậy)
HOSE	Ho Chi Minh Stock Exchange (Sở Giao dịch Chứng khoán TP.HCM)
LSTM	Long Short-Term Memory
MACD	Moving Average Convergence Divergence
NLP	Natural Language Processing (xử lý ngôn ngữ tự nhiên)
OHLCV	Open-High-Low-Close-Volume
PhoBERT	Pre-trained language model for Vietnamese (BERT tiếng Việt)
RSI	Relative Strength Index
TFT	Temporal Fusion Transformer
VN30	Chỉ số 30 cổ phiếu vốn hóa lớn trên HOSE

TÓM TẮT ĐỒ ÁN

Đồ án xây dựng một hệ thống dự báo xu hướng biến động giá cổ phiếu trên thị trường chứng khoán Việt Nam (sàn HOSE, nhóm VN30) dựa trên việc kết hợp phân tích cảm xúc tin tức tài chính tiếng Việt với dữ liệu chuỗi thời gian về giá.

Về hướng tiếp cận, hệ thống gồm hai nhánh. Nhánh cảm xúc sử dụng mô hình Transformer tiếng Việt PhoBERT được tinh chỉnh (fine-tune) để phân loại tin tức thành ba lớp tiêu cực, trung tính và tích cực, từ đó sinh ra đặc trưng cảm xúc theo mã và theo ngày. Nhánh giá sử dụng các đặc trưng kỹ thuật trích từ dữ liệu OHLCV điều chỉnh. Hai nhánh được hợp nhất và đưa vào mô hình chuỗi thời gian để dự báo xu hướng phiên kế tiếp theo ba lớp tăng, đi ngang và giảm.

Về cách giải quyết, đồ án tuân thủ một giao thức đánh giá chống rò rỉ dữ liệu gồm mốc cắt thông tin theo phiên, chia dữ liệu theo thời gian, kiểm định walk-forward và so sánh có kiểm soát giữa mô hình có và không dùng cảm xúc (ablation).

Về kết quả, đồ án cung cấp một pipeline hoàn chỉnh từ thu thập dữ liệu đến dự báo, cùng bảng so sánh các mô hình theo chỉ số macro-F1 kèm khoảng tin cậy, qua đó đo lường phần đóng góp của tín hiệu cảm xúc tin tức đối với bài toán dự báo xu hướng giá.

Từ khóa: dự báo xu hướng giá cổ phiếu, phân tích cảm xúc, PhoBERT, Transformer, chuỗi thời gian, HOSE, VN30.

Chương 1. MỞ ĐẦU

1.1. Lý do chọn đề tài

Thị trường chứng khoán là một hệ thống chịu ảnh hưởng đồng thời của thông tin kinh tế, hoạt động của doanh nghiệp, kỳ vọng của nhà đầu tư và trạng thái chung của thị trường. Trong số các nguồn thông tin đó, tin tức tài chính có thể làm thay đổi kỳ vọng trong thời gian ngắn, đặc biệt khi tin đề cập đến kết quả kinh doanh, thay đổi chính sách, hoạt động huy động vốn hoặc các sự kiện bất thường của doanh nghiệp. Vì vậy, việc chuyển một dòng tin văn bản thành tín hiệu định lượng và kiểm tra xem tín hiệu đó có bổ sung thông tin cho chuỗi giá hay không là một bài toán có ý nghĩa cả về xử lý ngôn ngữ tự nhiên lẫn phân tích chuỗi thời gian. Các nghiên cứu quốc tế đã khai thác cả điểm cảm xúc và biểu diễn ngữ cảnh của tin tức để dự báo chuyển động cổ phiếu, nhưng kết quả phụ thuộc mạnh vào thị trường, ngôn ngữ, cách gán nhãn và giao thức đánh giá của từng nghiên cứu [3], [7].

1.1.1. Bối cảnh tiếng Việt và thị trường Việt Nam

Đối với thị trường Việt Nam, phần lớn tin tức tài chính được công bố bằng tiếng Việt. Tiếng Việt có đặc trưng về từ ghép, tách từ, dấu thanh, cách viết tên doanh nghiệp và cách biểu đạt con số tài chính. Những đặc trưng này làm cho việc sử dụng trực tiếp một mô hình được huấn luyện chủ yếu trên tiếng Anh không phải là lựa chọn hiển nhiên. PhoBERT được xây dựng như một mô hình ngôn ngữ tiền huấn luyện cho tiếng Việt, do đó cung cấp một backbone phù hợp hơn cho các bài toán phân loại văn bản trong miền ngôn ngữ này [12]. Ở miền tiếng Anh, FinBERT cho thấy việc thích nghi backbone BERT với ngữ liệu tài chính có thể tạo ra biểu diễn hữu ích cho phân tích cảm xúc tài chính [18]. Hai hướng phát triển này gợi ý một nguyên tắc thiết kế cho đề tài: sử dụng mô hình ngôn ngữ phù hợp với ngôn ngữ của dữ liệu, đồng thời kiểm tra riêng chất lượng phân loại cảm xúc trước khi đưa tín hiệu đó vào mô hình dự báo giá.

Thị trường HOSE và nhóm cổ phiếu VN30 được chọn làm bối cảnh nghiên cứu vì đây là một phạm vi có lịch sử giao dịch tương đối dày, các mã có mức độ quan tâm thông tin cao và phù hợp với việc xây dựng dữ liệu theo ngày. Tuy nhiên, phạm vi này không đại diện cho toàn bộ thị trường chứng khoán Việt Nam. Mỗi mã có đặc điểm ngành, thanh khoản và mật độ tin tức khác nhau, còn quan hệ giữa tin và giá có thể thay đổi theo từng giai đoạn. Do đó, kết quả của đề tài được diễn giải như bằng chứng thực nghiệm trong phạm vi các mã được chọn, không phải như một khẳng định tổng quát cho mọi cổ phiếu.

1.1.2. Động cơ kết hợp hai loại dữ liệu

Dữ liệu giá chứa thông tin về phản ứng đã được thị trường thể hiện qua các đại lượng như giá mở cửa, giá cao nhất, giá thấp nhất, giá đóng cửa, khối lượng và lợi suất. Ngược lại, tin tức có thể chứa tín hiệu về sự kiện hoặc kỳ vọng trước khi phản ứng đó được phản ánh đầy đủ trong chuỗi giá. Hai nguồn dữ liệu vì vậy có tính bổ sung, nhưng không đồng nhất về dạng biểu diễn, thời điểm xuất hiện và độ tin cậy. Một mô hình chỉ dùng giá có thể bỏ qua thông tin văn bản, trong khi một mô hình chỉ dùng cảm xúc có thể bỏ qua xu hướng, biến động và trạng thái kỹ thuật của cổ phiếu.

Các kiến trúc kết hợp tin tức và giá trong nghiên cứu quốc tế thường đi từ việc trích xuất sentiment bằng FinBERT rồi đưa vào LSTM, đến việc sử dụng embedding ngữ cảnh hoặc LLM để mô hình hóa thông tin văn bản giàu hơn [4], [6], [7]. Tuy vậy, một mức cải thiện được báo cáo trên dữ liệu nước ngoài không tự động

chuyển thành hiệu quả trên HOSE. Đề tài vì thế đặt trọng tâm vào phép so sánh có kiểm soát giữa mô hình chỉ dùng giá và mô hình có thêm sentiment, dùng cùng cửa sổ thời gian, cùng cách tiền xử lý và cùng tập kiểm tra.

1.1.3. Vấn đề phương pháp cần giải quyết

Khó khăn cốt lõi không chỉ nằm ở việc chọn một mô hình sâu hơn. Có ít nhất bốn vấn đề phương pháp cần được xử lý đồng thời.

Thứ nhất, văn bản phải được gắn với đúng mã cổ phiếu và đúng thời điểm. Một bài viết được cập nhật sau thời điểm dự báo không thể được dùng để giải thích quyết định của phiên trước đó. Nếu tin sau giờ giao dịch, tin cuối tuần hoặc tin có timestamp không được xử lý nhất quán, mô hình có thể đạt điểm số cao do nhìn thấy thông tin tương lai.

Thứ hai, tín hiệu cảm xúc ở cấp bài viết phải được tổng hợp thành đặc trưng ở cấp mã và ngày. Việc chỉ lấy một bài nổi bật hoặc ghép toàn bộ tin trong ngày mà không xét số lượng, tỷ lệ lớp và ngày không có tin có thể làm mất thông tin về cường độ và độ phủ của tín hiệu.

Thứ ba, dữ liệu tài chính thường mất cân bằng và không dừng. Một mô hình có thể đạt accuracy tương đối cao chỉ nhờ dự đoán lớp phổ biến, trong khi bỏ sót lớp giảm hoặc lớp đi ngang. Đây là lý do đề tài dùng macro-F1 và balanced accuracy bên cạnh các chỉ số theo lớp.

Thứ tư, phép đánh giá phải tôn trọng thứ tự thời gian. Chuẩn hóa, điền khuyết, chọn đặc trưng, chọn ngưỡng nhân hoặc tinh chỉnh mô hình bằng dữ liệu tương lai đều làm suy giảm giá trị của kết quả ngoài mẫu. Các công trình về dự báo chuyển động cổ phiếu cũng cho thấy việc thiết kế benchmark, dữ liệu và cách đánh giá có vai trò quan trọng không kém việc thay đổi kiến trúc [3], [5].

1.1.4. Ý nghĩa của đề tài

Ý nghĩa của đề tài được xác định theo hai hướng. Về học thuật, đề tài xây dựng một quy trình nổi từ mô hình ngôn ngữ tiếng Việt đến mô hình chuỗi thời gian, qua đó kiểm tra một cách định lượng xem sentiment có tạo ra phần thông tin gia tăng khi dự báo xu hướng phiên kế tiếp hay không. Về kỹ thuật, đề tài tạo ra một pipeline có thể tái lập gồm thu thập dữ liệu, kiểm tra chất lượng, xử lý point-in-time, trích xuất xác suất cảm xúc, tổng hợp theo mã và ngày, huấn luyện mô hình, đánh giá walk-forward và ghi nhận cấu hình.

Đề tài không đặt mục tiêu chứng minh rằng sentiment luôn làm mô hình tốt hơn. Trong dữ liệu tài chính, tín hiệu văn bản có thể yếu, trễ, trùng với phản ứng giá hoặc chỉ có ích trong một số giai đoạn. Một kết quả không cải thiện, hoặc cải thiện nhỏ và không ổn định, vẫn có giá trị nếu được thu nhận bằng giao thức hợp lệ và được trình bày cùng giới hạn. Cách đặt vấn đề này phù hợp với hướng nghiên cứu gần đây, trong đó giá trị gia tăng của sentiment được xem là một giả thuyết cần kiểm tra thay vì một kết luận được giả định trước [8], [14].

1.2. Mục tiêu nghiên cứu

Mục tiêu tổng quát của đồ án là xây dựng và đánh giá một hệ thống dự báo xu hướng biến động giá cổ phiếu cho thị trường HOSE. Hệ thống sử dụng PhoBERT để tạo tín hiệu cảm xúc từ tin tức tài chính tiếng Việt, sử dụng đặc trưng kỹ thuật để biểu diễn chuỗi giá, sau đó hợp nhất hai nguồn thông tin trong mô hình dự báo ba lớp cho phiên kế tiếp. Trọng tâm của nghiên cứu là đo lường phần đóng góp biên của sentiment dưới giao thức đánh giá chống rò rỉ, không phải tối ưu một con số hiệu năng duy nhất.

1.2.1. Câu hỏi nghiên cứu

Đề tài trả lời ba câu hỏi nghiên cứu sau:

1. Mô hình PhoBERT được tinh chỉnh trên dữ liệu tin tức tài chính tiếng Việt có thể phân biệt ba lớp tích cực, trung tính và tiêu cực ở mức nào? Chất lượng có thay đổi ra sao khi so sánh head tuyến tính với một biến thể tăng cường có cùng dữ liệu?
2. Việc bổ sung đặc trưng cảm xúc vào mô hình dự báo có cải thiện macro-F1, balanced accuracy và macro OvR-AUC so với mô hình chỉ sử dụng giá hay không? Nếu có, mức chênh lệch có ổn định qua các cửa sổ thời gian hay chỉ xuất hiện ở một số fold?
3. Tín hiệu cảm xúc có biểu hiện khác nhau giữa các giai đoạn thị trường, giữa ngày có nhiều tin và ngày ít tin, hoặc giữa ngày gần với sự kiện và ngày thông thường hay không?

1.2.2. Mục tiêu cụ thể

Để trả lời các câu hỏi trên, đề án đặt ra các mục tiêu có thể kiểm chứng:

1. Xây dựng bộ dữ liệu tin tức tài chính tiếng Việt và dữ liệu giá điều chỉnh của một rổ 10 mã thuộc VN30 trong giai đoạn từ năm 2020 đến quý I năm 2026, kèm nguồn, timestamp, mã cổ phiếu và thông tin provenance.
2. Thiết kế quy trình làm sạch, loại trùng, ánh xạ bài viết theo mã và phiên giao dịch, trong đó dữ liệu chỉ được sử dụng nếu phù hợp với thời điểm dự báo.
3. Tinh chỉnh PhoBERT cho bài toán phân loại ba lớp, sinh xác suất của từng lớp cho mỗi bài viết và tổng hợp thành vector sentiment theo mã và ngày.
4. Trích xuất lợi suất và các chỉ báo kỹ thuật từ OHLCV điều chỉnh, chuẩn hóa các đặc trưng bằng tham số chỉ học từ phần huấn luyện của từng cửa sổ.
5. Xây dựng thang mô hình gồm majority, random, mô hình cổ điển chỉ dùng giá, LSTM chỉ dùng giá và LSTM hai nhánh có fusion giữa giá với sentiment. TFT được xem là tăng mở rộng sau khi graduation floor đã được kiểm tra.
6. Đánh giá dự báo bằng walk-forward có holdout cuối được khóa, báo cáo macro-F1 là chỉ số chính, balanced accuracy, macro OvR-AUC và các chỉ số theo lớp là chỉ số bổ sung, đồng thời ước lượng khoảng tin cậy cho chênh lệch ablation.
7. Ghi nhận cấu hình, seed, phiên bản thư viện, phiên bản dữ liệu và số lần thử, để kết quả có thể được tái lập hoặc kiểm tra lại khi có thay đổi dữ liệu.

1.2.3. Nguyên tắc diễn giải kết quả

Các mốc hiệu năng được nêu trong tài liệu nguồn, chẳng hạn kết quả phân loại của một seed dữ liệu hoặc mức directional accuracy của một nghiên cứu nước ngoài, chỉ được xem là tham chiếu kỹ thuật. Chúng được đo trên ngôn ngữ, thị trường, khoảng thời gian và cách chia dữ liệu khác với đề tài, nên không được dùng như ngưỡng đạt hoặc lời hứa cho HOSE. Tương tự, attention hoặc variable importance chỉ mô tả những tín hiệu mà mô hình đang sử dụng; chúng không đủ để kết luận sentiment là nguyên nhân gây ra biến động giá.

Vì mục tiêu là kiểm tra giá trị gia tăng, mọi phát biểu về việc sentiment hữu ích hay không hữu ích phải dựa trên các cặp mô hình được huấn luyện và kiểm tra dưới cùng một protocol. Một kết quả thuyết phục cần nêu rõ chênh lệch điểm số, độ biến thiên giữa các fold, khoảng tin cậy, phân bố lớp, phạm vi mã và các giới hạn của dữ liệu.

1.3. Đối tượng và phạm vi nghiên cứu

1.3.1. Đối tượng nghiên cứu

Đối tượng trung tâm của đề tài là mối quan hệ dự báo giữa cảm xúc của tin tức tài chính tiếng Việt và xu hướng lợi suất của cổ phiếu trong phiên kế tiếp. Mối quan hệ này được nghiên cứu thông qua hai loại dữ liệu. Loại thứ nhất là văn bản tin tức, gồm tiêu đề, nội dung khi có thể thu thập, thời điểm đăng hoặc cập nhật, nguồn và mã cổ phiếu được ánh xạ. Loại thứ hai là dữ liệu thị trường OHLCV theo ngày, trong đó giá được xử lý theo quy ước điều chỉnh để hạn chế ảnh hưởng của các sự kiện doanh nghiệp.

Về mô hình, đối tượng nghiên cứu gồm một backbone NLP tiếng Việt là PhoBERT và các biến thể head dùng để phân loại cảm xúc, cùng nhóm mô hình chuỗi thời gian gồm mô hình cổ điển, LSTM và Temporal Fusion Transformer. PhoBERT được chọn vì được tiền huấn luyện cho tiếng Việt, còn việc tham khảo FinBERT giúp đặt lựa chọn này trong dòng nghiên cứu NLP tài chính quốc tế [12], [18].

1.3.2. Phạm vi thị trường và mã cổ phiếu

Phạm vi thị trường là sàn HOSE. Rổ nghiên cứu gồm 10 mã thuộc VN30, được lựa chọn theo chỉ số thanh khoản, độ phủ tin và khả năng thu thập chuỗi giá liên tục. Danh sách mã và ngày bắt đầu sử dụng phải được lưu trong manifest, vì thành phần VN30 có thể thay đổi theo thời gian. Trong các bước chia dữ liệu, các mã được giữ trong cùng lịch phiên để việc so sánh theo ngày không bị lệch giữa các mã.

Việc chọn 10 mã là một giới hạn có chủ đích. Phạm vi vừa đủ để kiểm tra pipeline đa mã và giảm phụ thuộc vào một case study duy nhất, nhưng chưa đủ để đại diện cho mọi nhóm ngành hoặc mọi mức thanh khoản trên HOSE. Do đó, kết quả cần được gắn với rõ mã và khung thời gian cụ thể thay vì diễn giải như kết luận cho toàn thị trường.

1.3.3. Phạm vi thời gian và tần suất

Dữ liệu được giới hạn từ năm 2020 đến hết quý I năm 2026, tùy ngày cuối có dữ liệu hợp lệ của từng nguồn. Đơn vị quan sát chính là ngày giao dịch. Mục tiêu tại ngày t là dự báo lớp của lợi suất từ ngày t sang phiên giao dịch kế tiếp. Tần suất ngày phù hợp với mật độ tin tức và tránh mở rộng bài toán sang các vấn đề vi cấu trúc của dữ liệu trong ngày.

Mốc cutoff chính của protocol là 15 giờ theo múi giờ Việt Nam. Tin sau cutoff, tin vào cuối tuần hoặc ngày nghỉ được gán sang phiên giao dịch kế tiếp theo một quy tắc bảo thủ. Các trường hợp timestamp thiếu hoặc mâu thuẫn không được tự động suy đoán mà phải được đánh dấu, loại khỏi tập phân tích chính hoặc báo cáo riêng.

1.3.4. Phạm vi bài toán và giới hạn

Bài toán dự báo là phân loại ba lớp:

- **UP**: lợi suất phiên kế tiếp lớn hơn ngưỡng tăng;
- **FLAT**: lợi suất nằm trong vùng trung tính;
- **DOWN**: lợi suất nhỏ hơn ngưỡng giảm.

Ngưỡng được ước lượng trong tập huấn luyện của từng cửa sổ, không dùng phân vị của toàn bộ giai đoạn. Quy ước này giúp tránh việc phân phối lợi suất của tương lai ảnh hưởng đến nhãn của quá khứ. Đề tài không dự báo giá tuyệt đối, không nghiên cứu giao dịch tần suất cao, số lệnh, phái sinh hoặc khuyến nghị đầu tư.

Backtesting chiến lược, Sharpe và maximum drawdown được dành cho hướng phát triển, không phải tiêu chí kết luận của graduation floor.

1.3.5. Đóng góp dự kiến

Trong phạm vi được xác định, các đóng góp dự kiến gồm:

1. Một pipeline thực nghiệm tiếng Việt nổi dữ liệu tin tức với dữ liệu giá theo mã và thời điểm, có kiểm tra deduplication, provenance và cutoff.
2. Một quy trình dùng PhoBERT để tạo phân phối xác suất cảm xúc thay vì chỉ dùng một nhãn rời rạc, sau đó tổng hợp tín hiệu theo mã và ngày.
3. Một kiến trúc sàn gồm LSTM hai nhánh và fusion bằng concat, đặt cạnh các baseline chỉ giá để đo phần đóng góp biên của sentiment.
4. Một giao thức walk-forward có train-only preprocessing, holdout khóa cuối, macro-F1 và bootstrap CI, giúp tách kết quả mô hình khỏi các lỗi rò rỉ dữ liệu.

Các đóng góp trên là đóng góp về hệ thống thực nghiệm và khả năng kiểm chứng trong phạm vi dữ liệu đã chọn. Đồ án không tuyên bố tạo ra một mô hình tối ưu cho mọi thị trường, không tuyên bố quan hệ nhân quả giữa tin và giá, và không xem điểm số của các công trình trên dữ liệu nước ngoài là bằng chứng trực tiếp cho dữ liệu Việt Nam.

1.4. Cấu trúc đồ án

Phần còn lại của đồ án được tổ chức theo trình tự từ cơ sở vấn đề, khảo sát nghiên cứu, thiết kế phương pháp đến đánh giá và giới hạn.

1.4.1. Chương 2, Tổng quan

Chương 2 phân tích ba trụ nghiên cứu. Trụ thứ nhất là sentiment tài chính và backbone ngôn ngữ, từ FinBERT trong tiếng Anh đến PhoBERT trong tiếng Việt. Trụ thứ hai là mô hình chuỗi thời gian và Transformer cho dự báo chuyển động. Trụ thứ ba là hợp nhất tin tức với giá. Cuối chương, các hướng được so sánh theo dữ liệu, cách biểu diễn, mô hình, cách đánh giá và khả năng tái lập, từ đó xác định khoảng trống mà đề tài tập trung xử lý.

1.4.2. Chương 3, Phương pháp

Chương 3 trình bày cơ sở lý thuyết của Transformer, self-attention, PhoBERT, LSTM và TFT; sau đó mô tả kiến trúc hai nhánh, nguồn dữ liệu, tiền xử lý, gán nhãn, tạo đặc trưng, thang mô hình và giao thức đánh giá chống rò rỉ. Các quy tắc cutoff, chia dữ liệu và fit tham số được viết tường minh để người đọc có thể kiểm tra điểm nào của pipeline có nguy cơ nhìn thấy tương lai.

1.4.3. Chương 4, Kết quả thực nghiệm

Chương 4 mô tả thiết lập thực nghiệm, thống kê dữ liệu, chất lượng mô hình sentiment, kết quả dự báo và bảng ablation. Các ô kết quả chưa được đo được giữ ở dạng trống để điền từ manifest thực nghiệm. Phần bàn luận

được tổ chức quanh ba câu hỏi nghiên cứu, với nguyên tắc không thay thế số liệu thực bằng mốc tham chiếu từ công trình khác.

1.4.4. Chương 5 và Chương 6

Chương 5 tổng hợp những gì có thể kết luận trong phạm vi protocol, phân biệt kết quả đã đo với mục tiêu thiết kế và nêu các giới hạn. Chương 6 đề xuất các hướng mở rộng theo thứ tự ưu tiên, gồm đánh giá giá trị kinh tế, mở rộng ngữ liệu và mã, cải tiến fusion, xử lý concept drift và tăng khả năng giải thích.

Chương 2. TỔNG QUAN

Chương này phân tích các hướng nghiên cứu liên quan đến bài toán dự báo xu hướng cổ phiếu từ dữ liệu giá và tin tức. Việc khảo sát được tổ chức theo ba trụ. Trụ thứ nhất là phân tích cảm xúc tài chính, gồm các backbone ngôn ngữ và vấn đề thích nghi miền. Trụ thứ hai là mô hình chuỗi thời gian, từ baseline chỉ giá đến LSTM và Transformer. Trụ thứ ba là hợp nhất tin tức với giá, trong đó các nghiên cứu được phân biệt theo điểm cảm xúc, embedding ngữ cảnh, sự kiện và LLM. Sau cùng, chương đối chiếu các hướng theo dữ liệu, mục tiêu, cách đánh giá và mức độ tái lập để xác định vị trí của đề tài.

Một nguyên tắc quan trọng khi đọc các công trình trước là không đồng nhất kết quả tự báo cáo với bằng chứng có thể chuyển giao. Phần lớn tài liệu quốc tế sử dụng dữ liệu tiếng Anh, thị trường Mỹ hoặc Trung Quốc, khung thời gian và cách chia mẫu riêng. Vì vậy, các công trình được dùng ở đây chủ yếu để rút ra bài học về biểu diễn, kiến trúc và thiết kế thực nghiệm. Mọi mức cải thiện của hệ thống trên HOSE phải được kiểm tra lại bằng dữ liệu và protocol của đề tài.

2.1. Phân tích cảm xúc tin tức tài chính

Phân tích cảm xúc tin tức tài chính là bài toán suy ra thái độ hoặc tác động kỳ vọng của một đoạn văn đối với doanh nghiệp hay thị trường. Trong đề tài này, sentiment không được hiểu như cảm xúc tâm lý chung của tác giả, mà là tín hiệu định hướng cho phản ứng kỳ vọng của giá. Một bài viết có thể được gán tích cực nếu nội dung hàm ý triển vọng tốt hơn cho doanh nghiệp, tiêu cực nếu hàm ý rủi ro hoặc suy giảm, và trung tính nếu thông tin chủ yếu mô tả sự kiện mà chưa cho thấy hướng tác động rõ ràng. Cách định nghĩa theo tác động kỳ vọng giúp nhân phù hợp hơn với mục tiêu dự báo, nhưng cũng đòi hỏi hướng dẫn gán nhãn chặt chẽ vì nhiều tin có thể chứa cả hai chiều thông tin.

2.1.1. Từ mô hình ngôn ngữ tổng quát đến mô hình miền tài chính

BERT và các biến thể Transformer tạo biểu diễn ngữ cảnh bằng cách cho mỗi token tương tác với các token khác trong chuỗi. Khi được tinh chỉnh trên dữ liệu có nhãn, backbone này có thể học những dấu hiệu ngôn ngữ phù hợp với tác vụ phân loại. FinBERT là một ví dụ về việc đưa mô hình BERT vào miền truyền thông tài chính, qua đó tạo nền tảng cho các pipeline sentiment rồi dự báo chuyển động cổ phiếu [18]. Điểm đáng chú ý là từ điển tài chính không chỉ gồm các từ có sắc thái tích cực hoặc tiêu cực trong ngôn ngữ thông thường. Một từ như “tăng” có thể mô tả chi phí tăng, doanh thu tăng hoặc rủi ro tăng, nên cần xét ngữ cảnh và chủ thể được đề cập.

Đối với tiếng Việt, PhoBERT là lựa chọn backbone phù hợp vì được tiền huấn luyện trên ngữ liệu tiếng Việt và có tokenizer tương ứng với đặc trưng tách từ của ngôn ngữ này [12]. Tuy nhiên, PhoBERT không tự động trở thành mô hình sentiment tài chính chỉ nhờ tiền huấn luyện. Mô hình vẫn cần được tinh chỉnh trên dữ liệu có nhãn của miền tài chính, cần kiểm tra sự khác biệt giữa tiêu đề và nội dung, và cần đánh giá trên phân dữ liệu theo thời gian không trùng với dữ liệu huấn luyện.

2.1.2. Các công trình sentiment và chuyển động cổ phiếu quốc tế

Một dòng nghiên cứu kết hợp trực tiếp sentiment với mô hình chuỗi thời gian là FinBERT-LSTM. Halder xây dựng pipeline trong đó tín hiệu từ tin tức được đưa vào LSTM để dự báo giá, còn Gu và cộng sự phát triển một

biến thể cùng dòng với cách tổ chức dữ liệu và mô hình được cải tiến hơn [6], [7]. Các công trình này có giá trị như mẫu kiến trúc cho việc tách nhánh văn bản và nhánh giá, nhưng có những khác biệt cần lưu ý: dữ liệu chủ yếu là tiếng Anh, mục tiêu là giá hoặc biến động trong bối cảnh khác, và cách ghép đặc trưng không thể được xem là giao thức chuẩn cho HOSE.

Chen đề xuất sử dụng embedding ngữ cảnh từ BERT thay vì chỉ nén mỗi bài viết thành một điểm sentiment, sau đó đưa biểu diễn vào mô hình RNN cho dự báo chuyển động. Công trình này cho thấy việc giữ thông tin ngữ cảnh có thể là một hướng mở rộng đáng chú ý, đồng thời nhấn mạnh việc đánh giá bằng mô phỏng giao dịch thay vì chỉ nhìn vào accuracy [3]. Tuy nhiên, mô phỏng giao dịch vẫn phụ thuộc vào giả định về chi phí, thời điểm khớp lệnh và khả năng thực hiện, nên không thể thay thế việc kiểm tra phân loại ngoài mẫu trong graduation floor của đề tài.

Jiang nghiên cứu sentiment tài chính bằng FinBERT gắn với dự báo chuyển động, còn Siala và cộng sự tập trung trực tiếp vào câu hỏi sentiment do LLM tạo ra cải thiện dự báo ở mức nào [8], [14]. Những hướng này củng cố quan điểm rằng biến sentiment nên được đánh giá bằng phép so sánh có và không có tín hiệu trên cùng dữ liệu. Chúng không cho phép kết luận trước rằng tín hiệu do PhoBERT tạo ra sẽ có tác dụng tương tự trên văn bản tiếng Việt.

2.1.3. Đặc thù của sentiment tài chính tiếng Việt

Trong bối cảnh tiếng Việt, khó khăn đầu tiên là thiếu dữ liệu có nhãn lớn, nhất quán và có mô tả rõ ràng về tiêu chí gán nhãn. Một bộ dữ liệu tiêu đề có thể thuận tiện để khởi tạo fine-tune, nhưng tiêu đề ngắn thường bỏ qua điều kiện, thời hạn và chủ thể được mô tả trong thân bài. Ngược lại, dùng toàn văn giúp tăng ngữ cảnh nhưng làm tăng chi phí làm sạch, giới hạn độ dài và rủi ro một bài chứa nhiều sự kiện trái chiều.

Khó khăn thứ hai là sự trùng lặp theo nguồn. Cùng một thông cáo có thể được đăng lại ở nhiều trang hoặc gắn với nhiều mã. Nếu một bản sao xuất hiện ở cả train và test, mô hình có thể ghi nhớ câu chữ thay vì học quy luật sentiment. Vì thế, loại trùng cần được thực hiện ở cấp văn bản chuẩn hóa, đồng thời ghi lại URL, nguồn, thời điểm thu thập và hash dữ liệu.

Khó khăn thứ ba là sentiment của một bài không nhất thiết có tác động cùng chiều với lợi suất. Tin có thể đã được thị trường biết trước, có thể mô tả một sự kiện dài hạn nhưng không ảnh hưởng phiên kế tiếp, hoặc chỉ tác động đến biến động chứ không tác động đến chiều giá. Tài liệu nguồn của đề tài cũng xem việc phản ứng giá yếu hoặc không ổn định là khả năng cần kiểm tra, không phải dấu hiệu thất bại của mô hình.

2.1.4. Đánh giá chất lượng nhãn và đầu ra sentiment

Đánh giá sentiment cần tách khỏi đánh giá dự báo. Ở tầng thứ nhất, mô hình được kiểm tra bằng accuracy, precision, recall và F1 theo lớp, trong đó macro-F1 được ưu tiên khi phân bố lớp không cân bằng. Tập in-domain cần được gán nhãn theo hướng dẫn cố định; độ đồng thuận giữa hai người gán có thể báo cáo bằng Cohen’s kappa, còn từ ba người gán trở lên có thể dùng Fleiss’ kappa. Các mẫu bất đồng phải được ghi nhận thay vì loại bỏ tùy ý cho đến khi đạt điểm số mong muốn.

Đầu ra được dùng ở tầng dự báo không chỉ là nhãn argmax. Với mỗi bài viết, mô hình trả về vector xác suất ba chiều

$$\mathbf{p}_{i,j,t} = (p_{\text{NEG}}, p_{\text{NEU}}, p_{\text{POS}}), \quad \sum_c p_c = 1,$$

trong đó i là mã cổ phiếu, j là bài viết và t là ngày được ánh xạ. Vector này giữ lại mức độ không chắc chắn của mô hình. Sau đó, các vector được tổng hợp theo mã và ngày cùng với số tin, độ phân tán và cờ có tin. Cách

làm này cho phép mô hình dự báo phân biệt ngày có nhiều tin trung tính với ngày hoàn toàn không có tin.

2.2. Dự báo xu hướng giá bằng mô hình chuỗi thời gian

Nhánh chuỗi thời gian biểu diễn trạng thái thị trường bằng lịch sử OHLCV, lợi suất và các chỉ báo kỹ thuật. Mục tiêu của nhánh này không phải tái tạo chính xác mức giá, mà là cung cấp một baseline có năng lực để kiểm tra sentiment có bổ sung thông tin hay không. Các nghiên cứu dự báo xu hướng quốc tế thường sử dụng lịch sử giá kết hợp đặc trưng kỹ thuật, sau đó mở rộng sang mô hình sâu hoặc mô hình quan hệ giữa nhiều mã [5], [17].

2.2.1. Baseline chỉ giá và các mô hình cổ điển

Baseline majority dự đoán lớp xuất hiện nhiều nhất trong phần huấn luyện. Baseline random sinh dự đoán theo phân bố lớp của phần huấn luyện và dùng seed cố định. Hai baseline này có vai trò kiểm tra xem mô hình học được tín hiệu vượt qua một quy tắc đơn giản hay không. Nếu một mô hình sâu chỉ nhỉnh hơn majority ở accuracy nhưng thua macro-F1, kết luận về hiệu quả cần dựa vào chỉ số cân bằng hơn.

Nhóm mô hình cổ điển chỉ giá gồm Logistic Regression, Random Forest và XGBoost. Chúng được huấn luyện trên cùng tập đặc trưng kỹ thuật với dữ liệu được chuẩn hóa trong từng cửa sổ. Mục đích không phải chạy thật nhiều thuật toán, mà tạo một mốc kiểm tra đủ rõ cho nhánh giá. Nếu mô hình có sentiment không vượt được mốc này, việc thêm một kiến trúc sâu hơn chưa chắc giải quyết đúng vấn đề dữ liệu.

2.2.2. LSTM cho phụ thuộc ngắn hạn và dài hạn

LSTM sử dụng trạng thái ẩn và trạng thái ô nhớ để cập nhật thông tin qua các thời điểm. Nhờ các cổng vào, cổng quên và cổng ra, LSTM có thể giữ hoặc loại bỏ một phần thông tin trong cửa sổ lịch sử. Trong các pipeline dự báo tài chính gắn với tin tức, LSTM thường được dùng như bộ mã hóa chuỗi hoặc bộ dự báo cuối [6], [7]. Các mốc accuracy cao được tài liệu nguồn tổng hợp cho dữ liệu Việt Nam phải được đọc thận trọng nếu không có kiểm tra leakage, metric theo lớp hoặc metric giao dịch. Vì khác biệt về thị trường, cách tạo nhãn và cách chia dữ liệu, các mốc đó chỉ là bối cảnh tham khảo, không phải kết quả của đề tài.

Ở bình diện quốc tế, các nghiên cứu dự báo chuyển động cũng dùng nhiều biến thể mạng hồi quy và thường kết hợp thêm thông tin từ tin tức hoặc quan hệ giữa các mã [3], [7]. Vì mục tiêu của đề tài là đo incremental value của sentiment, LSTM chỉ giá và LSTM hai nhánh được giữ cùng cửa sổ, chiến lược chia dữ liệu và ngân sách huấn luyện. Đây là điều kiện cần để chênh lệch giữa hai mô hình có thể được quy về việc thêm modality, thay vì quy về thay đổi quy mô mạng.

2.2.3. Transformer cho chuỗi thời gian

Transformer dùng self-attention để tính mức liên hệ giữa các vị trí trong chuỗi. Khác với việc chỉ truyền trạng thái tuần tự, attention có thể kết nối trực tiếp các thời điểm xa nhau và xử lý nhiều kênh đặc trưng trong cùng một lớp. Trong dự báo cổ phiếu, Transformer còn có thể được mở rộng để mô hình hóa phụ thuộc giữa nhiều mã hoặc giữa nhiều loại tín hiệu. Boyle và Kalita nghiên cứu hướng spatiotemporal Transformer cho dự báo chuyển động, còn Omranpour và cộng sự nghiên cứu Transformer bậc cao cho dữ liệu chuỗi thời gian đa phương thức [1], [13].

Temporal Fusion Transformer được xem trong đề tài như tăng mở rộng của thang mô hình. Ý tưởng chính là kết hợp xử lý chuỗi cục bộ, cơ chế chọn biến, các cổng điều tiết và attention để mô hình có thể sử dụng nhiều

nhóm biến. Với bài toán hiện tại, TFT phải được cấu hình cho phân loại ba lớp, sử dụng đầu ra kích thước 3 và loss phân loại. Không được lấy cấu hình hồi quy phân vị mặc định rồi diễn giải kết quả như phân loại. Các trọng số attention hoặc variable importance của TFT chỉ là bằng chứng mô tả phụ thuộc vào mô hình, không phải bằng chứng nhân quả.

2.2.4. Dịch chuyển phân phối và quan hệ giữa các mã

Một số hướng nghiên cứu quốc tế không chỉ mô hình hóa từng mã độc lập. HIST khai thác thông tin chia sẻ giữa mã và khái niệm, REST đưa sự kiện vào quan hệ giữa các cổ phiếu, còn DoubleAdapt tập trung vào thích nghi khi phân phối dữ liệu thay đổi [16], [17], [19]. MTMD, DishFT-GNN và S³G tiếp tục phát triển các dạng bộ nhớ đa quy mô, đồ thị động hoặc biểu diễn trạng thái để xử lý nhiễu và quan hệ liên mã [10], [11], [15].

Các công trình này cho thấy bài toán dự báo xu hướng có thể chịu ảnh hưởng của quan hệ ngành, khái niệm và concept drift. Tuy nhiên, đưa đồ thị nhiều mã vào graduation floor sẽ làm tăng số giả định về quan hệ liên cổ phiếu và độ phức tạp của đánh giá. Đề tài trước hết giữ mô hình hai nhánh trên từng mã, dùng nhiều mã trong cùng lịch walk-forward để kiểm tra tính ổn định. Quan hệ liên mã và thích nghi online được dành cho các hướng phát triển sau khi pipeline cơ sở đã được khóa.

2.3. Kết hợp tin tức và giá (multimodal)

Hợp nhất multimodal là quá trình đưa thông tin từ văn bản và chuỗi số vào một bộ dự báo chung. Hai nguồn khác nhau ở kích thước, tần suất, độ trễ và mức độ tin cậy, nên phép nối đặc trưng đơn giản có thể là một baseline hữu ích nhưng chưa chắc mô hình hóa được tương tác giữa chúng. Các nghiên cứu quốc tế cho thấy có thể phân biệt một số mức hợp nhất, từ điểm sentiment theo ngày, embedding văn bản, sự kiện chi tiết đến LLM và cross-attention [4], [7].

2.3.1. Hợp nhất bằng điểm sentiment

Ở mức đơn giản nhất, mô hình NLP biến mỗi bài thành nhãn hoặc vector xác suất. Các vector được gom theo mã và ngày, sau đó nối với vector kỹ thuật trước khi đưa vào Logistic Regression, cây quyết định hoặc LSTM. Ưu điểm của cách này là dễ kiểm tra, dễ ablation và ít tốn tài nguyên. Nhược điểm là toàn bộ thông tin trong nhiều bài được nén vào một số trung bình, làm mất thứ tự bài, sự kiện và quan hệ giữa câu chữ với đặc trưng giá.

FinBERT-LSTM là mẫu điển hình của cách tiếp cận sentiment rồi chuỗi thời gian [6], [7]. Với đề tài, cách tiếp cận này được chuyển sang PhoBERT và dữ liệu tiếng Việt. Tuy nhiên, bản thân việc dùng PhoBERT không đủ để tạo đóng góp. Đóng góp cần được chứng minh bằng việc mô hình có sentiment được đặt cạnh mô hình price-only dưới cùng protocol, và bằng việc kiểm tra các trường hợp không có tin.

2.3.2. Hợp nhất bằng embedding ngữ cảnh và sự kiện

Thay vì chỉ dùng điểm sentiment, một hướng khác giữ lại embedding ngữ cảnh của tiêu đề hoặc bài viết. Chen sử dụng contextualized embedding từ BERT cho dự báo movement, cho thấy cách biểu diễn này có thể chứa các tín hiệu vượt ra ngoài phân cực ba lớp [3]. Một hướng giàu hơn nữa là trích xuất sự kiện chi tiết, chẳng hạn chủ thể, loại sự kiện, hướng tác động và thời gian. Chen và cộng sự nghiên cứu việc đưa các sự kiện fine-grained vào dự báo chuyển động, qua đó gợi ý rằng cảm xúc chỉ là một phần của thông tin văn bản [2].

Tuy nhiên, embedding toàn văn có kích thước lớn và có thể chứa thông tin không liên quan. Event extraction cũng cần schema, gán nhãn và kiểm tra mapping phức tạp. Vì đề tài đặt mục tiêu tốt nghiệp có thể tái lập, graduation floor chọn xác suất sentiment được tổng hợp theo ngày. Embedding và event-level signal được xem là phép thử nhạy cảm hoặc hướng phát triển, không thay thế baseline chính.

2.3.3. Hợp nhất động và LLM

Các công trình gần đây dùng LLM để kết hợp dữ liệu giá có cấu trúc với tin tức hoặc để mô hình hóa cách tin được lan truyền. Elahi và Taghvaei đặt bài toán kết hợp dữ liệu tài chính với bài viết qua LLM, còn Liang và cộng sự đưa yếu tố dissemination và ngữ cảnh vào FinGPT [4], [9]. Những hướng này có thể giữ nhiều ngữ cảnh hơn, nhưng phụ thuộc vào kích thước mô hình, chi phí, phiên bản checkpoint và khả năng tái lập. Nếu dùng mô hình thương mại, việc xác định đúng thời điểm kiến thức và tái tạo cùng đầu ra còn khó hơn.

Với bài toán của đề tài, PhoBERT mở được chọn thay cho LLM thương mại vì có thể ghi nhận checkpoint, tokenizer, seed và cấu hình. Lựa chọn này không có nghĩa PhoBERT luôn tốt hơn LLM, mà giúp phạm vi nghiên cứu có thể kiểm tra trong điều kiện tài nguyên của đồ án. Siala và cộng sự cho thấy câu hỏi “sentiment có thật sự làm tăng chất lượng dự báo” cần được đo riêng, một điểm phù hợp với thiết kế ablation của đề tài [14].

2.3.4. Các cơ chế fusion

Có thể phân loại cơ chế fusion thành ba nhóm:

1. **Early fusion:** chuẩn hóa hai nhóm đặc trưng rồi nối chúng trước bộ mã hóa. Cách này đơn giản nhưng dễ để nhóm có nhiều chiều lẫn át nhóm còn lại.
2. **Late fusion:** mỗi nhánh tạo ra biểu diễn hoặc dự đoán riêng, sau đó một lớp kết hợp các đầu ra. Cách này tách biệt hơn nhưng có thể bỏ lỡ tương tác chi tiết giữa một sự kiện và một trạng thái giá.
3. **Gated hoặc cross-attention fusion:** một nhánh học cách chọn thông tin từ nhánh kia theo thời điểm và ngữ cảnh. Cách này giàu biểu đạt hơn, nhưng cần nhiều dữ liệu và dễ làm tăng phương sai khi số mã chỉ ở mức 10.

Đề tài dùng concat sau hai nhánh LSTM làm mức sàn vì đây là phép hợp nhất có thể kiểm tra, dễ giữ ngân sách tham số gần với price-only LSTM và phù hợp với ablation. Gated cross-attention hoặc dual-stream Transformer được nêu ở Chương 6, không được mặc định xem là đối thủ bắt buộc của graduation floor. Higher Order Transformers là ví dụ cho việc đưa nhiều chuỗi vào một Transformer, nhưng mức phức tạp của hướng đó phù hợp hơn với tăng mở rộng sau khi baseline đã ổn định [13].

2.3.5. Đánh giá multimodal và nguy cơ diễn giải quá mức

Một mô hình multimodal có thể đạt điểm cao vì nhiều lý do khác nhau. Tín hiệu sentiment có thể phản ánh lại các biến giá đã được dùng trong cùng ngày, tin có thể xuất hiện sau thời điểm quyết định, hoặc dữ liệu train và test có thể chứa các bản tin trùng lặp. Vì vậy, chỉ so sánh một mô hình fusion với một mô hình price-only khác cấu hình không đủ để khẳng định giá trị của văn bản.

Thiết kế của đề tài yêu cầu bốn điều kiện. Thứ nhất, mapping tin theo timestamp phải được audit. Thứ hai, cùng một cửa sổ, seed, preprocessing và holdout phải được dùng cho hai nhánh ablation. Thứ ba, chỉ số chính phải tính trên dự đoán ngoài mẫu theo thứ tự thời gian. Thứ tư, chênh lệch phải đi kèm độ bất định, chẳng hạn bootstrap theo khối ngày. Cách đánh giá giàu hơn như mô phỏng giao dịch có thể bổ sung trong tương lai, như tinh thần được minh họa ở các nghiên cứu dùng trading simulation [3], [5].

2.4. Khoảng trống nghiên cứu và định vị đề tài

2.4.1. Tổng hợp theo ba trụ

Từ khảo sát, khoảng trống không được hiểu là chưa từng có ai dùng sentiment, LSTM hay Transformer riêng lẻ. Các thành phần cơ bản đã xuất hiện trong nhiều dòng nghiên cứu: FinBERT cho sentiment tài chính tiếng Anh [18], PhoBERT cho tiếng Việt [12], FinBERT-LSTM cho pipeline tin tức và giá [6], [7], contextualized embedding cho movement [3], và Transformer cho chuỗi thời gian đa phương thức hoặc spatiotemporal [1], [13].

Khoảng trống nằm ở sự kết hợp và cách kiểm chứng trong bối cảnh cụ thể. Trong phạm vi tài liệu được khảo sát cho đề tài, chưa có một pipeline được khóa đầy đủ các thành phần sau trên cùng rõ nhiều mã HOSE: backbone PhoBERT mở cho tin tiếng Việt, ánh xạ point-in-time theo cutoff, nhánh giá với đặc trưng kỹ thuật, mô hình hai nhánh, ablation có và không có sentiment, walk-forward không rò rỉ và báo cáo chênh lệch có khoảng tin cậy. Đây là tuyên bố về phạm vi khảo sát và thiết kế của đề tài, không phải tuyên bố rằng không tồn tại bất kỳ triển khai nào khác.

2.4.2. So sánh các hướng nghiên cứu

Bảng 2.1: So sánh các nhóm nghiên cứu liên quan với phạm vi đề tài.

Nhóm	Đặc điểm chính	Hạn chế khi áp dụng cho đề tài	Vai trò
Sentiment tài chính	FinBERT và PhoBERT tạo nhãn hoặc xác suất cảm xúc cho văn bản [12], [18]	Khác ngôn ngữ, miền, cách gán nhãn và thời điểm tin	Backbone, tăng tiền xử lý
Price-only LSTM	Mô hình hóa cửa sổ OHLCV và chỉ báo kỹ thuật theo thời gian [7]	Không kiểm tra giá trị gia tăng của văn bản	Baseline sâu
Transformer movement	Attention cho phụ thuộc thời gian, đa phương thức hoặc liên mã [1], [13]	Phức tạp, chưa có bằng chứng trực tiếp trên HOSE	TFT stretch
News-price fusion	Nối sentiment, embedding, event hoặc LLM với giá [3], [4]	Dễ trộn lẫn khác biệt dữ liệu, rò rỉ và giả định thị trường	Mẫu kiến trúc
Graph và meta-learning	Khai thác quan hệ liên mã và concept drift [17], [19]	Ngoài phạm vi 10 mã độc lập và ngân sách đồ án	Bối cảnh tương lai

2.4.3. Định vị và giả thuyết kiểm chứng

Đề tài được định vị như một nghiên cứu thực nghiệm multimodal tiếng Việt, không phải một cuộc thi chọn kiến trúc mới. Mức sàn gồm majority, random, price-only classical, price-only LSTM và LSTM hai nhánh với concat. TFT chỉ được chạy sau khi mức sàn có số liệu và đã kiểm tra loss phân loại, output kích thước 3 cùng holdout. Cách xếp tầng này kế thừa tinh thần xây dựng đối chứng và kiểm tra đặc trưng trước khi tăng độ phức

tạp, phù hợp với việc các nghiên cứu price-only cho thấy tiền xử lý và lựa chọn đặc trưng có thể ảnh hưởng lớn đến kết quả [5].

Giả thuyết chính là vector xác suất sentiment tổng hợp có thể cung cấp thông tin gia tăng cho dự báo xu hướng phiên kế tiếp sau khi đã kiểm soát lịch sử giá. Giả thuyết phụ là phân gia tăng, nếu tồn tại, không nhất thiết ổn định ở mọi ngày mà có thể rõ hơn quanh ngày có nhiều tin hoặc giai đoạn biến động cao. Đây là giả thuyết mô tả cần được kiểm tra bằng phân tầng dữ liệu; không được biến nó thành khẳng định rằng tin luôn gây ra biến động.

2.4.4. Tiêu chí để tuyên bố đóng góp

Một tuyên bố đóng góp chỉ được đưa ra khi thỏa mãn các điều kiện:

- dữ liệu và phạm vi mã được mô tả rõ, bao gồm bản ghi thiếu hoặc bị loại;
- cutoff, công thức nhân, phép chia theo thời gian và quy trình fit tham số được ghi trong manifest;
- kết quả sentiment và kết quả dự báo được tách thành hai tầng;
- mô hình có sentiment và price-only dùng cùng protocol, seed hoặc tập seed đã định trước;
- macro-F1, balanced accuracy, macro OvR-AUC và chỉ số theo lớp được báo cáo cùng khoảng tin cậy khi có thể;
- các kết luận nêu rõ tính tự báo cáo của tài liệu tham khảo và không suy rộng ngoài 10 mã thuộc VN30 trong giai đoạn nghiên cứu.

Theo đó, đóng góp an toàn nhất của đề tài là một pipeline tái lập để đo lường phần đóng góp biên của sentiment tiếng Việt dưới đánh giá walk-forward có kiểm soát. Nếu ablation không cho thấy cải thiện, kết quả đó vẫn trả lời được câu hỏi nghiên cứu và giúp tránh kết luận quá mức từ một mô hình phức tạp.

Chương 3. PHƯƠNG PHÁP

Chương này trình bày cơ sở lý thuyết, dữ liệu, kiến trúc hệ thống và giao thức đánh giá của đề tài. Phương pháp được thiết kế theo nguyên tắc xây dựng một mức sàn có thể kiểm chứng trước, sau đó mới mở rộng sang mô hình phức tạp hơn. Mức sàn phải bao gồm baseline, mô hình chỉ dùng giá, mô hình hai nhánh có sentiment, ablation, walk-forward và kiểm tra train-only preprocessing. Temporal Fusion Transformer được xem là tăng mở rộng, không thay thế các đối chứng bắt buộc.

3.1. Tổng quan kiến trúc hệ thống

Hệ thống gồm hai nhánh xử lý song song rồi hợp nhất. Nhánh cảm xúc nhận tin tức tiếng Việt, tinh chỉnh PhoBERT để tạo xác suất ba lớp và tổng hợp tín hiệu theo mã, ngày. Nhánh giá nhận OHLCV điều chỉnh, tạo lợi suất và chỉ báo kỹ thuật theo lịch phiên. Hai nhánh được căn chỉnh theo mã và ngày sau khi áp dụng quy tắc cutoff, tạo thành feature table dùng cho dự báo lớp UP, FLAT hoặc DOWN của phiên kế tiếp.

3.1.1. Nguyên tắc thiết kế

Kiến trúc được xây dựng theo năm nguyên tắc. Thứ nhất, mọi dữ liệu phải có mốc thời gian và nguồn gốc để kiểm tra tính hợp lệ theo thời điểm. Thứ hai, tín hiệu sentiment được biểu diễn bằng xác suất thay vì chỉ một nhãn cứng để giữ thông tin không chắc chắn. Thứ ba, mô hình có sentiment phải được so sánh với price-only dưới cùng điều kiện. Thứ tư, các phép biến đổi học tham số phải được fit trong từng cửa sổ huấn luyện. Thứ năm, tăng mở rộng chỉ được thực hiện khi không làm giảm chất lượng kiểm chứng của mức sàn.

3.1.2. Cơ sở lý thuyết của Transformer và self-attention

Transformer biểu diễn một chuỗi token bằng các vector và dùng cơ chế attention để đánh trọng số các vị trí liên quan. Với ma trận truy vấn Q , khóa K và giá trị V , scaled dot-product attention được viết như sau:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V, \quad (3.1)$$

trong đó d_k là số chiều của khóa. Việc chia cho $\sqrt{d_k}$ giúp ổn định độ lớn của tích vô hướng trước khi đưa qua softmax. Multi-head attention thực hiện nhiều phép chiếu song song rồi ghép các kết quả, nhờ đó mô hình có thể học các dạng quan hệ khác nhau giữa token. Trong mô hình ngôn ngữ, attention giúp một token được biểu diễn theo ngữ cảnh của cả câu. FinBERT và PhoBERT là hai ví dụ về việc dùng backbone thuộc họ BERT cho miền tài chính hoặc tiếng Việt [12], [18].

Một encoder Transformer thường gồm multi-head attention, mạng feed-forward theo từng vị trí, kết nối tắt và chuẩn hóa. Vì self-attention không tự biểu diễn thứ tự, mô hình cần thông tin vị trí hoặc một cách mã hóa thứ tự tương đương. Trong đề tài, PhoBERT đã có tokenizer và embedding theo thiết kế của backbone. Ở nhánh chuỗi thời gian, nếu TFT được chạy, thứ tự của các ngày được giữ trong TimeSeriesDataSet và mọi biến được đánh dấu theo vai trò tĩnh, đã biết trước hoặc quan sát được.

3.1.3. Cơ sở lý thuyết của PhoBERT

PhoBERT là mô hình ngôn ngữ tiền huấn luyện dành cho tiếng Việt. Đầu vào của PhoBERT được tách từ theo quy ước phù hợp rồi đi qua tokenizer BPE để sinh chuỗi token con. Khi tinh chỉnh cho sentiment, một vector đại diện được lấy từ encoder và đưa qua head phân loại. Với ba lớp, logits $\mathbf{z}$ được chuyển thành xác suất:

$$p_c = \frac{\exp(z_c)}{\sum_{k=1}^3 \exp(z_k)}, \quad c \in \{\text{NEG}, \text{NEU}, \text{POS}\}. \quad (3.2)$$

Việc chọn PhoBERT không loại bỏ yêu cầu thích nghi miền. Tên công ty, mã cổ phiếu, thuật ngữ tài chính và cách viết phần trăm có thể khác ngữ liệu tiền huấn luyện. Vì vậy, dữ liệu tinh chỉnh phải giữ dấu tiếng Việt, ghi rõ quy tắc tách từ, giới hạn độ dài, xử lý thực thể và cách loại trùng. Mô hình được kiểm tra trên một tập in-domain theo thời gian, thay vì chỉ dựa vào một mốc accuracy của tập seed.

3.1.4. Cơ sở lý thuyết của LSTM

LSTM đọc chuỗi theo thứ tự thời gian và duy trì trạng thái ẩn $\mathbf{h}_t$ cùng trạng thái ô nhớ $\mathbf{c}_t$. Với đầu vào $\mathbf{x}_t$, một bước cập nhật có thể mô tả bằng:

$$\mathbf{i}_t = \sigma(W_i \mathbf{x}_t + U_i \mathbf{h}_{t-1} + \mathbf{b}_i), \quad (3.3)$$

$$\mathbf{f}_t = \sigma(W_f \mathbf{x}_t + U_f \mathbf{h}_{t-1} + \mathbf{b}_f), \quad (3.4)$$

$$\mathbf{o}_t = \sigma(W_o \mathbf{x}_t + U_o \mathbf{h}_{t-1} + \mathbf{b}_o), \quad (3.5)$$

$$\tilde{\mathbf{c}}_t = \tanh(W_c \mathbf{x}_t + U_c \mathbf{h}_{t-1} + \mathbf{b}_c), \quad (3.6)$$

$$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t, \quad (3.7)$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t). \quad (3.8)$$

Trong đó $\mathbf{i}_t$, $\mathbf{f}_t$ và $\mathbf{o}_t$ lần lượt là cổng vào, cổng quên và cổng ra. LSTM phù hợp với mức sàn vì có thể mô hình hóa một cửa sổ giá hoặc một cửa sổ đặc trưng sentiment mà không yêu cầu đồ thị liên mã. Trong hệ thống, LSTM được dùng ở hai nhánh với số ngày quan sát giống nhau để phép so sánh có ý nghĩa.

3.1.5. Cơ sở lý thuyết của Temporal Fusion Transformer

TFT được đưa vào như một mô hình mở rộng cho chuỗi nhiều biến. Tư tưởng của TFT là kết hợp các bộ mã hóa chuỗi với cơ chế chọn biến và attention có gating. Một biến có thể được đánh trọng số khác nhau theo từng thời điểm và từng trạng thái dự báo. Trong bài toán này, các biến động lượng, volatility, tỷ lệ sentiment và cờ có tin có thể được xem là những nhóm biến khác nhau.


TFT trong đề tài phải được cấu hình cho phân loại. Đầu ra cuối là logits kích thước 3 và hàm mất mát là cross-entropy. Cấu hình hồi quy phân vị, nếu có trong thư viện, không được dùng cho mục tiêu phân loại. Variable importance và attention được lưu như chứng cứ mô tả cách mô hình sử dụng biến, nhưng không được diễn giải như ảnh hưởng nhân quả. Các nghiên cứu Transformer cho movement và chuỗi thời gian đa phương thức cho thấy hướng này có tiềm năng biểu diễn phong phú, song độ phức tạp và khác biệt thị trường vẫn cần được kiểm tra riêng [1], [13].

3.1.6. Luồng xử lý tổng thể

Luồng dữ liệu gồm các bước:

1. khóa phạm vi mã, thời gian, cutoff, công thức nhãn và seed;
2. thu thập tin tức, OHLCV và lịch giao dịch, sau đó lưu provenance;
3. làm sạch, loại trùng, kiểm tra timestamp và ánh xạ bài viết theo mã;
4. tạo nhánh sentiment và nhánh giá bằng các phép biến đổi độc lập;
5. căn chỉnh hai nhánh theo mã và ngày giao dịch, tạo nhãn ở thời điểm hợp lệ;
6. chạy thang mô hình từ baseline đến LSTM hai nhánh, TFT chỉ khi đủ điều kiện;
7. đánh giá walk-forward, ablation và bootstrap, rồi lưu manifest kết quả.

Hình 3.1 minh họa các bước chính của pipeline, trong đó các khối TFT và gated cross-attention được đánh dấu là mở rộng. Cách thể hiện này giúp tách phần graduation floor khỏi các lựa chọn chưa chắc được chạy trong thực nghiệm cuối.



Hình 3.1: Kiến trúc tổng thể của pipeline dự báo xu hướng giá.

3.2. Thu thập và tiền xử lý dữ liệu

3.2.1. Phạm vi dữ liệu và nguồn thu thập

Dữ liệu gồm hai bảng chính. Bảng tin tức chứa mã bản ghi, URL, nguồn, tiêu đề, nội dung nếu có, timestamp đăng hoặc cập nhật, thời điểm thu thập và mã cổ phiếu. Bảng giá chứa mã, ngày giao dịch, OHLCV điều chỉnh và cờ chất lượng. Giai đoạn nghiên cứu kéo dài từ năm 2020 đến quý I năm 2026, với khoảng 10 mã HOSE thuộc VN30 được chốt trong manifest.

Nguồn tin ưu tiên là Vietstock theo mã vì cách ánh xạ trực tiếp giúp giảm mơ hồ giữa bài viết và cổ phiếu. CafeF, VnEconomy hoặc Stockbiz chỉ được dùng bổ sung khi kiểm tra được độ phủ, nội dung, timestamp và điều khoản sử dụng. Dữ liệu giá được thu thập qua thư viện vnstock với nguồn VCI theo cấu hình của đề tài. Một nguồn bổ sung như vnquant chỉ được dùng để cross-check nếu semantics của adjusted price, coverage và schema được so sánh trước, không tự động trộn vào tập chính.

3.2.2. Kiểm tra chất lượng và provenance

Mỗi bản ghi tin được gán hash của văn bản chuẩn hóa, nguồn và URL. Bản ghi trùng tiêu đề, nội dung và timestamp gần nhau được đánh dấu để kiểm tra trước khi loại. Nếu một bài được gán với nhiều mã hợp lệ, hệ thống giữ quan hệ nhiều mã nhưng ghi rõ cách mở rộng bản ghi. Nếu không thể xác định mã hoặc thời điểm, bản ghi không được đưa vào feature table chính.

Các thống kê phải bao gồm số bài theo nguồn, theo mã và theo năm, tỷ lệ thiếu nội dung, tỷ lệ thiếu timestamp, số bản ghi trùng, độ phủ ngày có tin và số phiên giá hợp lệ. Cùng với đó, manifest lưu thời điểm crawl, phiên bản mã nguồn, hash file dữ liệu và quy tắc làm sạch. Mục tiêu của bước này là tránh tạo ra một corpus có vẻ lớn nhưng không thể truy nguyên hoặc không thể tái lập.

3.2.3. Dữ liệu giá

Dữ liệu OHLCV được sử dụng theo giá điều chỉnh để tính lợi suất và hạn chế đứt gãy do chia tách, cổ tức hoặc sự kiện doanh nghiệp. Với giá đóng cửa điều chỉnh $C_{i,t}^{\text{adj}}$ của mã i tại ngày t , lợi suất mục tiêu được định nghĩa là:

$$r_{i,t+1} = \frac{C_{i,t+1}^{\text{adj}}}{C_{i,t}^{\text{adj}}} - 1. \quad (3.9)$$

Các kiểm tra cơ bản gồm thứ tự thời gian, ngày trùng, giá không dương, khối lượng không hợp lệ và phiên bị thiếu. Không dùng giá trị của ngày $t + 1$ để tạo đặc trưng tại ngày t . Những ngày đầu cửa sổ không đủ dữ liệu cho moving average hoặc volatility được loại khỏi mẫu của mô hình hoặc xử lý bằng một quy tắc đã ghi trong manifest.

3.2.4. Dữ liệu tin tức và ánh xạ theo phiên

Tin giữ cả tiêu đề và nội dung nhằm phục vụ audit, nhưng chính sách đầu vào phải được khóa trước khi huấn luyện. Graduation floor ưu tiên tiêu đề vì phù hợp với seed công khai và giảm khác biệt độ dài. Nội dung được lưu để kiểm tra và có thể dùng trong một phân tích nhạy cảm nếu được gán nhãn, tách thời gian và báo cáo riêng.

Tất cả timestamp được chuyển về múi giờ Việt Nam. Với mỗi ngày giao dịch t , chỉ tin có timestamp không muộn hơn 15 giờ của ngày đó được xem là có thể quan sát tại mốc quyết định. Tin sau 15 giờ được chuyển sang nhóm của phiên giao dịch kế tiếp theo quy tắc bảo thủ, vì vậy không được dùng để tạo đặc trưng của phiên đã đóng. Tin vào cuối tuần, ngày nghỉ hoặc ngày không giao dịch cũng được gán đến phiên hợp lệ tiếp theo. Quy tắc này có thể làm trễ một phần tín hiệu, nhưng giúp giảm nguy cơ đánh giá lạc quan do dùng thông tin xuất hiện sau cutoff.

3.2.5. Tiền xử lý văn bản tiếng Việt

Quy trình tiền xử lý văn bản gồm các bước:

1. chuẩn hóa Unicode, khoảng trắng, ký hiệu phần trăm và cách viết số;
2. tách từ bằng công cụ phù hợp với PhoBERT, giữ dấu tiếng Việt và các token tài chính có ý nghĩa;
3. nhận diện và che một số thực thể như tổ chức, địa danh hoặc mã cổ phiếu khi mục tiêu là học ngữ cảnh, đồng thời giữ bản gốc trong vùng provenance;
4. giới hạn độ dài và xử lý bài rỗng bằng quy tắc loại bản ghi, không tự tạo câu thay thế;
5. dùng tokenizer BPE của checkpoint PhoBERT và ghi lại chiều dài, số token bị cắt cùng cấu hình.

Không xóa một cách máy móc mọi số liệu, dấu phần trăm hoặc ký hiệu tăng giảm, vì chúng có thể mang tín hiệu tài chính. Nếu một phép loại dấu câu hoặc mask thực thể được sử dụng, ảnh hưởng của nó phải được giữ cố định giữa các split. Mọi biến đổi nhìn thấy toàn bộ corpus, chẳng hạn vocabulary mới hoặc thống kê chọn token, phải được loại khỏi đường đi của thực nghiệm chính hoặc fit trong phần train.

3.2.6. Tạo tập sentiment và gán nhãn

Tập seed gồm các tiêu đề tài chính đã gán nhãn ba lớp, được dùng để kiểm tra nhanh pipeline. Tập in-domain được mở rộng bằng hướng dẫn gán nhãn cố định. Người gán nhãn đọc nội dung ở dạng được phép sử dụng, xác định chủ thể chính, sự kiện và hướng tác động kỳ vọng đến giá trong ngắn hạn. Các quy tắc cơ bản là:

- tích cực nếu thông tin hàm ý triển vọng hoặc tác động có lợi rõ ràng;
- tiêu cực nếu thông tin hàm ý rủi ro, suy giảm hoặc tác động bất lợi rõ ràng;
- trung tính nếu chỉ thông báo, mô tả hoặc chưa đủ bằng chứng để xác định chiều.

Tin có hai chiều trái ngược được gán theo tác động nổi trội nếu hướng dẫn cho phép, hoặc giữ trong nhóm bất đồng để thảo luận. Báo cáo annotation phải ghi số người gán, số mẫu, phân bố lớp, tỷ lệ bất đồng và Cohen's hoặc Fleiss' kappa tùy số người gán. Các mẫu dùng để đánh giá dự báo phải được tách theo thời gian khỏi dữ liệu được dùng để fine-tune sentiment trong fold tương ứng.

3.3. Nhánh cảm xúc: tinh chỉnh PhoBERT

3.3.1. Thiết lập bài toán phân loại

Mỗi bài viết hợp lệ được xem là một mẫu có nhãn y_j thuộc ba lớp NEGATIVE, NEUTRAL hoặc POSITIVE. Mô hình sử dụng checkpoint `vinai/phobert-base` làm encoder, theo sau là dropout và head tuyến tính. Logits được chuyển thành xác suất theo Phương trình 3.2. Head tuyến tính là cấu hình chính vì có ít tham số bổ sung và dễ tái lập. Một biến thể PhoBERT kết hợp CNN hoặc BiLSTM chỉ được dùng để so sánh nếu thời gian và dữ liệu cho phép.

PhoBERT được chọn theo ngôn ngữ của dữ liệu, trong khi FinBERT được xem là đối chiếu khái niệm ở miền tiếng Anh [12], [18]. Không dịch toàn bộ tin sang tiếng Anh trong graduation floor, vì dịch máy có thể làm thay đổi sắc thái, tên riêng và thông tin số. Nếu có thí nghiệm dịch, đó phải là một baseline riêng với phiên bản công cụ và cấu hình được ghi lại.

3.3.2. Chia dữ liệu và huấn luyện

Tập sentiment được chia theo thời gian hoặc theo nguyên tắc không trùng nguồn trước khi huấn luyện. Tập validation dùng để chọn epoch, learning rate và ngưỡng dừng sớm. Tập test chỉ được dùng một lần cho báo cáo cuối của cấu hình đã khóa. Khi mô hình sentiment được dùng trong walk-forward, có hai lựa chọn hợp lệ: tinh chỉnh lại trong từng fold bằng dữ liệu nhân quá khứ, hoặc dùng một checkpoint đóng băng được huấn luyện hoàn toàn trước phần test. Không được fine-tune trên nhân hoặc văn bản gần với thời gian tương lai rồi gọi kết quả là ngoài mẫu.

Hàm mất mát cơ bản là cross-entropy:

$$\mathcal{L}_{\text{CE}} = -\frac{1}{N} \sum_{j=1}^N \log p_{j,y_j}. \quad (3.10)$$

Nếu lớp mất cân bằng, dùng trọng số w_c được tính từ phần train:

$$\mathcal{L}_{\text{WCE}} = -\frac{1}{N} \sum_{j=1}^N w_{y_j} \log p_{j,y_j}. \quad (3.11)$$

Trọng số, cách lấy mẫu lại, seed, batch size, số epoch, tokenizer và checkpoint đều được ghi vào manifest. Không chọn checkpoint dựa trên kết quả của tập test.

3.3.3. Đầu ra xác suất và tổng hợp theo mã, ngày

Gọi $\mathcal{N}_{i,t}$ là tập tin hợp lệ của mã i được ánh xạ vào ngày t , với $n_{i,t} = |\mathcal{N}_{i,t}|$. Xác suất trung bình của lớp c được tính bởi:

$$\bar{p}_{i,t,c} = \frac{1}{n_{i,t}} \sum_{j \in \mathcal{N}_{i,t}} p_{i,j,t,c}, \quad n_{i,t} > 0. \quad (3.12)$$

Vector đặc trưng sentiment gồm $\bar{p}_{\text{NEG}}$, $\bar{p}_{\text{NEU}}$, $\bar{p}_{\text{POS}}$, chênh lệch $\bar{p}_{\text{POS}} - \bar{p}_{\text{NEG}}$, số tin, độ lệch chuẩn của xác suất, tỷ lệ tin tích cực hoặc tiêu cực và biến nhị phân `has_news`. Ngày không có tin được gán prior trung tính cho vector xác suất, đặt số tin và các tỷ lệ bằng không, đồng thời đặt `has_news`=0. Ngày có tin trung tính vẫn có số tin dương và `has_news`=1, nên hai tình huống không bị đồng nhất hoàn toàn.

Các đặc trưng được tổng hợp sau cutoff. Không được dùng số tin hoặc xác suất của bài đăng sau cutoff để mô tả ngày đã kết thúc. Nếu một bài gán với nhiều mã, việc nhân bản đặc trưng được ghi rõ để tránh đếm bài như một quan sát độc lập trong phân tích độ không chắc chắn.

3.4. Nhánh giá và ghép đặc trưng

3.4.1. Đặc trưng kỹ thuật

Từ adjusted OHLCV, hệ thống tạo các nhóm đặc trưng sau:

- lợi suất ngày và lợi suất log trong các cửa sổ ngắn;
- tỷ lệ giữa giá đóng cửa với moving average ở một số độ dài;
- RSI để mô tả động lượng tương đối;
- MACD và chênh lệch giữa các đường trung bình;
- thay đổi khối lượng, OBV hoặc đại lượng tỷ lệ với khối lượng;
- độ lệch chuẩn lợi suất trong cửa sổ để mô tả volatility.

Các chỉ báo được tính từ dữ liệu đến ngày quan sát t . Để giảm phụ thuộc vào mức giá tuyệt đối, các đại lượng có đơn vị giá được chuyển thành tỷ lệ hoặc sai khác tương đối. Các giá trị khuyết ở đầu chuỗi được xử lý bằng cách loại mẫu chưa đủ lịch sử hoặc dùng quy tắc imputation đã khóa. Scaler, imputer và bất kỳ phép chọn đặc trưng nào đều chỉ fit trên train của fold.

3.4.2. Căn chỉnh hai nguồn dữ liệu

Mỗi dòng feature table có khóa (i, t) gồm vector giá $\mathbf{x}_{i,t}^p$, vector sentiment $\mathbf{x}_{i,t}^s$, cờ chất lượng, thông tin mã và nhãn mục tiêu. Với cửa sổ dài L , đầu vào của mô hình tại ngày t là:

$$X_{i,t}^p = [\mathbf{x}_{i,t-L+1}^p, \dots, \mathbf{x}_{i,t}^p], \quad X_{i,t}^s = [\mathbf{x}_{i,t-L+1}^s, \dots, \mathbf{x}_{i,t}^s]. \quad (3.13)$$

Các mã được chia theo ngày để bảo đảm mọi mẫu cùng một fold dùng cùng mốc lịch. Nếu ngày không có tin, vector sentiment vẫn được tạo theo quy tắc ở trên, không loại bỏ ngày một cách có chọn lọc vì có thể tạo sai lệch giữa giai đoạn nhiều tin và ít tin.

3.4.3. Gán nhãn xu hướng phiên kế tiếp

Lợi suất mục tiêu được tính theo Phương trình 3.9. Với cửa sổ huấn luyện w , chọn hai phân vị q_w^- và q_w^+ từ tập các lợi suất chỉ trong phần train. Quy tắc phân lớp là:

$$y_{i,t+1} = \begin{cases} \text{DOWN}, & r_{i,t+1} < q_w^-, \\ \text{FLAT}, & q_w^- \leq r_{i,t+1} \leq q_w^+, \\ \text{UP}, & r_{i,t+1} > q_w^+. \end{cases} \quad (3.14)$$

Trong protocol chính, q_w^- và q_w^+ được lấy từ hai phân vị thấp và cao đã khóa trong cấu hình. Nếu thay bằng ngưỡng cố định, ngưỡng đó phải được ghi rõ và không được điều chỉnh dựa trên test. Mục đích của việc fit ngưỡng theo train là tránh cho phân bố lợi suất của giai đoạn tương lai quyết định trước tỷ lệ lớp của giai đoạn quá khứ.

3.4.4. Hợp nhất bằng LSTM hai nhánh

Nhánh giá và nhánh sentiment sử dụng hai encoder LSTM riêng:

$$\mathbf{h}_{i,t}^p = \text{LSTM}_p(X_{i,t}^p), \quad \mathbf{h}_{i,t}^s = \text{LSTM}_s(X_{i,t}^s). \quad (3.15)$$

Hai trạng thái cuối được ghép bằng concat và đưa qua một lớp hợp nhất:

$$\mathbf{z}_{i,t} = [\mathbf{h}_{i,t}^p; \mathbf{h}_{i,t}^s], \quad \hat{\mathbf{y}}_{i,t+1} = \text{softmax}(W_2 \phi(W_1 \mathbf{z}_{i,t} + \mathbf{b}_1) + \mathbf{b}_2), \quad (3.16)$$

trong đó ϕ là hàm kích hoạt và $\hat{\mathbf{y}}$ là xác suất của ba lớp. Mô hình price-only dùng cùng nhánh giá và head tương ứng nhưng loại bỏ $\mathbf{h}^s$. Khi so sánh, số chiều ẩn, cửa sổ, seed và ngân sách huấn luyện phải được giữ gần nhất có thể. Chênh lệch tham số do nhánh sentiment phải được báo cáo, không che giấu như một thay đổi kiến trúc không liên quan.

3.5. Thang mô hình dự báo

Đồ án xây dựng theo nguyên tắc thang leo. Mỗi tầng trả lời một câu hỏi kiểm chứng riêng và chỉ mở rộng khi tầng trước có dữ liệu hợp lệ.

3.5.1. Tầng baseline

Tầng đầu gồm majority và random. Majority cho biết mức điểm có thể đạt nếu chỉ luôn chọn lớp phổ biến. Random được sinh theo một quy tắc đã khóa, có seed và được chạy trên cùng tập test. Khi cần, có thể báo cáo thêm random đều để phân biệt ảnh hưởng của phân bố lớp với ảnh hưởng của mô hình.

3.5.2. Tầng mô hình cổ điển chỉ giá

Logistic Regression, Random Forest và XGBoost chỉ nhận vector đặc trưng giá. Các mô hình này cung cấp mốc phi tuần tự cho việc kiểm tra feature engineering. Chúng không được phép nhận bất kỳ cột sentiment nào, kể cả số tin, cờ có tin hoặc metadata phát sinh từ văn bản.

3.5.3. Tầng LSTM chỉ giá

LSTM chỉ giá nhận X^p trong một cửa sổ cố định và dự báo ba lớp. Đây là baseline sâu để tách câu hỏi “mạng LSTM có khai thác được lịch sử giá hay không” khỏi câu hỏi “sentiment có bổ sung thông tin hay không”. Các siêu tham số được chọn trên validation và giữ nguyên khi chạy ablation.

3.5.4. Tầng LSTM hai nhánh có sentiment

Đây là graduation floor của đề tài. Nhánh sentiment nhận chuỗi đặc trưng tổng hợp theo ngày, nhánh giá nhận chuỗi kỹ thuật, hai trạng thái được ghép bằng concat và đi qua head phân loại. Thí nghiệm ablation chạy hai cấu hình:

1. **Price-only:** chỉ sử dụng X^p ;
2. **Price plus sentiment:** sử dụng cả X^p và X^s .

Hai cấu hình phải có cùng ngày train, validation, test, cùng cách fit preprocessing, cùng seed hoặc cùng tập seed, cùng quy tắc nhân và cùng metric. Nếu sentiment không cải thiện, kết quả vẫn được giữ và phân tích theo độ ổn định, thay vì thay đổi protocol cho đến khi xuất hiện một bảng điểm có lợi.

3.5.5. Tầng TFT mở rộng

TFT chỉ được chạy khi các baseline và LSTM hai nhánh đã có số liệu, không còn lỗi cutoff và còn đủ nguồn lực. Mô hình nhận các biến thời gian, biến tĩnh hoặc biến quan sát theo cấu hình rõ ràng, sử dụng output size bằng 3 và loss phân loại. Kết quả TFT chỉ được so sánh với các tầng trước nếu dùng cùng holdout và quy tắc tạo nhãn. Nếu không kiểm soát được cấu hình loss hoặc thời gian chạy, TFT được cắt khỏi thực nghiệm chính mà không làm giảm acceptance của graduation floor.

3.5.6. Huấn luyện và kiểm soát độ phức tạp

Mô hình được huấn luyện bằng cross-entropy cho ba lớp, có early stopping theo macro-F1 trên validation. Dropout, weight decay và gradient clipping có thể được dùng để hạn chế overfitting, nhưng các lựa chọn phải được khóa trước hoặc ghi đầy đủ số lần thử. Mỗi mô hình lưu checkpoint tốt nhất theo metric đã chọn, seed, cửa sổ, số tham số và thời gian huấn luyện. Không sử dụng test để điều chỉnh kiến trúc sau mỗi lần chạy.

3.6. Giao thức đánh giá chống rò rỉ

Đánh giá là phần trung tâm của phương pháp. Một split theo thời gian đơn giản chưa đủ để bảo đảm sạch nếu scaler, threshold, feature selection hoặc checkpoint đã nhìn thấy dữ liệu tương lai. Giao thức được thiết kế theo walk-forward, có holdout cuối được khóa và có audit các phép biến đổi.

3.6.1. Walk-forward và holdout cuối

Tất cả mã được chia theo mốc ngày chung. Một cửa sổ walk-forward gồm train ở quá khứ, validation ở đoạn kế tiếp và test ở đoạn sau nữa. Sau khi hoàn tất lựa chọn cấu hình, holdout cuối được giữ nguyên, chỉ chạy một lần để báo cáo. Có thể dùng expanding window để tăng dần dữ liệu train hoặc rolling window để giới hạn độ dài lịch sử; lựa chọn nào được dùng phải ghi trong manifest cùng độ dài các đoạn và bước dịch cửa sổ.

Với expanding window, không được trộn mẫu của một ngày giữa train và test. Các mã có cùng ngày phải nằm trong cùng split để tránh một mã tiết lộ thông tin về trạng thái thị trường cho mã khác qua cách chia lệch. Các mẫu tạo từ cửa sổ lịch sử cũng phải được cắt theo ngày mục tiêu, không chỉ theo ngày bắt đầu cửa sổ.

3.6.2. Kiểm soát điểm nhìn và các phép biến đổi

Bảng kiểm leakage gồm các hạng mục:

- timestamp tin và cutoff 15 giờ;
- mapping cuối tuần, ngày nghỉ và tin sau giờ;
- adjusted price và công thức lợi suất mục tiêu;
- scaler, imputer và phép chọn đặc trưng chỉ fit trên train;
- ngưỡng q_w^- , q_w^+ chỉ tính từ lợi suất train;
- nhãn sentiment dùng để fine-tune và checkpoint của từng fold;
- deduplication không để cùng bài hoặc bản sao gần giống xuất hiện ở hai split;
- lựa chọn siêu tham số chỉ dùng train và validation, không dùng holdout.

Mỗi fold cần lưu một số ví dụ audit bằng tay, chẳng hạn tin trước cutoff, tin sau cutoff, tin cuối tuần và ngày không có tin. Nếu phát hiện bản ghi không thể xác minh, bản ghi đó bị loại khỏi phân tích chính và tỷ lệ loại được báo cáo.

3.6.3. Các chỉ số đánh giá

Với ma trận nhầm lẫn của ba lớp, precision, recall và F1 được tính riêng cho từng lớp. Macro-F1 là trung bình số học của F1 ba lớp:

$$\text{MacroF1} = \frac{1}{3} \sum_{c=1}^3 F1_c. \quad (3.17)$$

Balanced accuracy là trung bình recall của ba lớp. Macro OvR-AUC được tính bằng cách xem mỗi lớp lần lượt là positive và hai lớp còn lại là negative, rồi lấy trung bình các AUC. Directional accuracy có thể được báo cáo như tỷ lệ dự đoán đúng lớp, nhưng không được dùng một mình khi phân bố lớp mất cân bằng. Các chỉ số phải được tính trên dự đoán ngoài mẫu của từng fold, sau đó tổng hợp theo một quy tắc đã khóa.

3.6.4. Ablation và khoảng tin cậy

Phép ablation chính so sánh price-only với price plus sentiment. Cùng một ngày test được dùng cho hai mô hình để tạo chênh lệch theo cặp:

$$\Delta_m = m(\text{price} + \text{sentiment}) - m(\text{price-only}), \quad (3.18)$$

với m là macro-F1, balanced accuracy hoặc macro OvR-AUC. Khoảng tin cậy được ước lượng bằng bootstrap theo khối ngày hoặc theo fold để hạn chế giả định độc lập sai trong chuỗi thời gian. Số lần resample, seed và cách xử lý fold phải được ghi lại. Nếu khoảng tin cậy của Δ_m chứa 0, kết luận phù hợp là chưa có bằng chứng rõ ràng sentiment cải thiện metric đó trong protocol hiện tại, không phải khẳng định sentiment vô dụng trong mọi bối cảnh.

3.6.5. Phân tích độ bền và điều kiện phát huy tín hiệu

Sau khi bảng graduation floor ổn định, có thể phân tầng kết quả theo ngày có nhiều tin và ít tin, theo volatility thấp hoặc cao, theo trạng thái tăng hoặc giảm, và theo mã cổ phiếu. Các phân tích này phải được xem là bổ sung vì làm tăng số phép so sánh. Số lần thử và tiêu chí phân tầng cần được ghi rõ để tránh chọn riêng một nhóm có kết quả đẹp. Kết quả theo mã có thể có phương sai lớn khi một số mã có ít tin, vì vậy cần báo cáo cả số quan sát của từng nhóm.

3.6.6. Giải thích mô hình

Với LSTM hai nhánh, giải thích cơ bản dùng feature ablation hoặc occlusion: lần lượt che nhóm sentiment, số tin, hoặc một nhóm chỉ báo rồi đo thay đổi metric. Với TFT, variable importance và attention được lưu như mô tả bổ sung. Không có phương pháp nào trong số này tự chứng minh rằng biến sentiment gây ra lợi suất. Mọi diễn giải phải dùng các cụm như “mô hình đặt trọng số cao hơn” hoặc “metric thay đổi khi che biến”, không dùng cụm “sentiment gây ra biến động”.

3.6.7. Tái lập và báo cáo

Mỗi lần chạy cần lưu seed, phiên bản Python và thư viện, checkpoint, danh sách mã, hash dữ liệu, thời gian crawl, cấu hình model, split, metric và số lần thử. Báo cáo phải phân biệt ba trạng thái: đã đo, chưa chạy và không áp dụng. Các ô số chưa có kết quả không được thay bằng số tham chiếu từ bài khác. Cùng với bảng điểm, cần báo cáo coverage, số bản ghi bị loại, phân bố lớp, kappa của nhãn và các giới hạn về nguồn dữ liệu.

Bảng 3.1 tóm tắt các quyết định thiết kế chính của pipeline.

Bảng 3.1: Tóm tắt các quyết định thiết kế chính.

Thành phần	Lựa chọn
Mô hình cảm xúc	PhoBERT-base fine-tune, ba lớp và đầu ra xác suất
Mô hình chuỗi thời gian	LSTM hai nhánh là mức sàn, TFT là tầng mở rộng
Hợp nhất	Concatenate hai trạng thái cuối rồi phân loại
Phạm vi	10 mã VN30 trên HOSE, dữ liệu từ năm 2020 đến quý I năm 2026
Cutoff	15 giờ theo múi giờ Việt Nam, tin sau giờ chuyển sang phiên kế tiếp
Nhãn	Lợi suất phiên kế tiếp, ngưỡng chỉ fit trên train
Đánh giá	Walk-forward, holdout khóa cuối, macro-F1 là chỉ số chính

Chương 4. KẾT QUẢ THỰC NGHIỆM

Chương này mô tả cách tổ chức thực nghiệm, thống kê dữ liệu, kết quả phân loại cảm xúc, kết quả dự báo và cấu trúc bàn luận. Các con số trong các bảng là khung để điền từ manifest và log chạy thực tế. Việc để trống một ô kết quả là có chủ đích, nhằm phân biệt giữa thiết kế thí nghiệm và quan sát đã được đo. Không sử dụng số liệu tham chiếu của nghiên cứu khác để thay thế cho kết quả trên HOSE.

4.1. Thiết lập thực nghiệm

4.1.1. Môi trường và cấu hình phần mềm

Thực nghiệm cần được chạy trong một môi trường có thể ghi nhận phiên bản hệ điều hành, Python, PyTorch, Transformers, scikit-learn, vntstock và các thư viện chỉ báo kỹ thuật. Việc tinh chỉnh PhoBERT có thể sử dụng GPU trên Colab, Kaggle hoặc máy cục bộ. Tên GPU, dung lượng bộ nhớ, thời gian chạy và checkpoint phải được lưu trong manifest. Nếu chạy lại trên phần cứng khác, sai khác về tốc độ hoặc kết quả do tính không xác định của phép toán phải được ghi rõ.

Các giá trị seed được cố định cho bước chia dữ liệu, lấy mẫu, khởi tạo mô hình và bootstrap. Tên checkpoint, tokenizer, chính sách cắt token, batch size, learning rate, optimizer, số epoch, early stopping và dropout phải được ghi cho cả nhánh sentiment và nhánh dự báo. Tập test và holdout không được dùng để chọn siêu tham số.

Bảng 4.1: Thông tin thiết lập cần ghi nhận trong manifest.

Hạng mục	Giá trị cần điền
Hệ điều hành và Python	<i>Chưa điền</i>
GPU và bộ nhớ	<i>Chưa điền</i>
Phiên bản PhoBERT và tokenizer	<i>Chưa điền</i>
Phiên bản thư viện	<i>Chưa điền</i>
Seed và số lần chạy	<i>Chưa điền</i>
Cửa sổ, cutoff và holdout	<i>Chưa điền</i>
Hash dữ liệu và mã nguồn	<i>Chưa điền</i>

4.1.2. Thiết kế chia dữ liệu

Dữ liệu được chia theo ngày giao dịch, dùng cùng mốc lịch cho các mã. Các cửa sổ walk-forward gồm train, validation và test theo thứ tự thời gian. Sau khi chọn cấu hình bằng các cửa sổ phát triển, một holdout cuối được khóa và chỉ dùng để báo cáo. Trong mỗi cửa sổ, scaler, imputer, ngưỡng nhân và các phép chọn đặc trưng được fit trên train. Quy tắc này nhằm tránh tình trạng điểm số được cải thiện do thông tin của tương lai, một vấn đề có thể xuất hiện ngay cả khi split đã có thứ tự thời gian.

Kết quả phải báo cáo số fold, ngày bắt đầu và kết thúc của mỗi fold, số mẫu theo mã, phân bố lớp và số mẫu bị loại do thiếu lịch sử hoặc timestamp. Nếu một fold không đủ coverage tin, tình trạng đó phải được nêu thay vì tự động thay bằng dữ liệu bổ sung.

4.1.3. Cấu hình huấn luyện và tiêu chí chọn mô hình

PhoBERT được chọn checkpoint theo macro-F1 trên validation sentiment. Mô hình dự báo được chọn theo macro-F1 validation, sau đó đánh giá trên test của fold. Cấu hình có và không có sentiment sử dụng cùng ngân sách thử nghiệm. Nếu có nhiều seed, báo cáo trung bình, độ lệch chuẩn và quy tắc tổng hợp; nếu chỉ có một seed do giới hạn tài nguyên, phải ghi rõ đó là giới hạn của kết quả.

Các baseline được chạy trước khi thử TFT. Đây là điều kiện quan trọng vì những nghiên cứu về movement thường có sự khác biệt lớn về dữ liệu và metric, nên kết quả của một mô hình phức tạp không thể được đọc tách rời khỏi baseline của chính tập dữ liệu [3], [5].

4.2. Thống kê dữ liệu

4.2.1. Quy mô corpus tin

Phần này cần báo cáo số bài sau từng cổng xử lý: số bản ghi thô, số bản ghi có mã, số bản ghi có timestamp hợp lệ, số bản ghi sau deduplication và số bài được đưa vào fine-tune hoặc suy luận. Bảng thống kê nên tách theo nguồn, theo mã và theo năm để cho thấy corpus có bị tập trung vào một nguồn hoặc một giai đoạn hay không.

Bảng 4.2: Thống kê corpus tin tức sau các bước kiểm tra.

Chỉ tiêu	Số lượng hoặc tỷ lệ
Bản ghi thô	Chưa điền
Bản ghi có mã cổ phiếu	Chưa điền
Bản ghi có timestamp hợp lệ	Chưa điền
Bản ghi trùng bị loại	Chưa điền
Bài có nội dung ngoài tiêu đề	Chưa điền
Số ngày có ít nhất một tin	Chưa điền
Tỷ lệ ngày không có tin	Chưa điền

Độ phủ tin cần được đặt cạnh độ phủ giá. Một mã có nhiều phiên nhưng ít tin không nhất thiết là dữ liệu xấu, nhưng mô hình phải biết ngày đó không có quan sát văn bản. Vì vậy, cột số tin và `has_news` cần được thống kê, không gộp ngày không tin vào lớp neutral mà không có cờ phân biệt.

4.2.2. Quy mô dữ liệu giá và phân bố nhãn

Đối với dữ liệu giá, cần báo cáo số phiên theo mã, ngày đầu, ngày cuối, số ngày thiếu và số mẫu còn lại sau khi tạo đủ cửa sổ lịch sử. Nhãn UP, FLAT và DOWN được tính từ ngưỡng fit trên train của từng fold. Do đó, phân bố nhãn ở train, validation, test và holdout có thể khác nhau. Bảng dưới đây giữ các ô số để điền từ pipeline.

Bảng 4.3: Thống kê dữ liệu giá và phân bố nhãn ba lớp.

Chỉ tiêu	UP	FLAT	DOWN	Tổng
Train	Chưa điền	Chưa điền	Chưa điền	Chưa điền
Validation	Chưa điền	Chưa điền	Chưa điền	Chưa điền
Test theo fold	Chưa điền	Chưa điền	Chưa điền	Chưa điền
Holdout cuối	Chưa điền	Chưa điền	Chưa điền	Chưa điền

Nếu lớp FLAT chiếm tỷ lệ lớn, accuracy sẽ khó phản ánh khả năng nhận diện UP và DOWN. Nếu ngưỡng phân vị tạo tỷ lệ lớp gần cân bằng nhưng các mã riêng lẻ vẫn lệch, kết quả phải nêu cả hai mức phân bố. Đây là lý do macro-F1 và balanced accuracy được đặt làm chỉ số trung tâm.

4.3. Kết quả phân loại cảm xúc

4.3.1. Chất lượng nhãn in-domain

Trước khi phân tích điểm dự báo, cần báo cáo quy trình gán nhãn: số người gán, tiêu chí, số mẫu bất đồng, cách giải quyết bất đồng, Cohen's hoặc Fleiss' kappa và phân bố ba lớp. Nếu kappa thấp, cần giải thích những trường hợp ngôn ngữ mơ hồ hoặc tin chứa nhiều sự kiện, không chỉ chọn lại mẫu có đồng thuận cao.

Bảng 4.4: Thông tin gán nhãn tập sentiment in-domain.

Chỉ tiêu	Giá trị
Số người gán nhãn	Chưa điền
Số mẫu được gán	Chưa điền
Tỷ lệ NEGATIVE	Chưa điền
Tỷ lệ NEUTRAL	Chưa điền
Tỷ lệ POSITIVE	Chưa điền
Cohen's hoặc Fleiss' kappa	Chưa điền

4.3.2. Chỉ số mô hình sentiment

Mô hình PhoBERT được đánh giá trên tập test sentiment đã khóa. Ngoài accuracy, cần báo cáo precision, recall và F1 theo từng lớp vì mô hình có thể nhận diện tốt lớp phổ biến nhưng bỏ sót lớp ít. Macro-F1 là số trung bình không phụ thuộc trực tiếp vào số lượng của từng lớp. Nếu so sánh head tuyến tính với PhoBERT plus CNN hoặc BiLSTM, mọi mô hình phải dùng cùng dữ liệu, cùng split và cùng cách tính metric.

Bảng 4.5: Kết quả phân loại sentiment trên tập test, số liệu để điền sau.

Mô hình	Accuracy	Macro-F1	F1 NEG	F1 POS
PhoBERT plus head tuyến tính	Chưa điền	Chưa điền	Chưa điền	Chưa điền
PhoBERT plus CNN hoặc BiLSTM	Chưa điền	Chưa điền	Chưa điền	Chưa điền

Các số liệu sentiment chỉ chứng minh chất lượng của tầng phân loại trên tập test của tầng đó. Chúng không tự chứng minh rằng tín hiệu có giá trị dự báo. Một checkpoint có macro-F1 cao vẫn có thể tạo tín hiệu yếu nếu tín bị trễ, không được ánh xạ đúng mã, hoặc nội dung đã được thị trường biết trước. Vì vậy, đầu ra dùng cho nhánh dự báo phải được sinh đúng theo cutoff và fold tương ứng.

4.4. Kết quả dự báo xu hướng và ablation

Bảng 4.6 giữ cấu trúc thang mô hình đã đặt ra trong Chương 3. Các số được để trống để điền sau khi chạy đủ baseline và holdout. Cần ghi rõ metric là trung bình trên các fold, kết quả holdout hay một giá trị gộp từ toàn bộ dự đoán ngoài mẫu.

Bảng 4.6: So sánh mô hình theo macro-F1, số liệu để điền sau.

Mô hình	Macro-F1	Balanced Acc.	OvR-AUC
Majority	Chưa điền	Chưa điền	Chưa điền
Random	Chưa điền	Chưa điền	Chưa điền
Chỉ giá, XGBoost	Chưa điền	Chưa điền	Chưa điền
LSTM, chỉ giá	Chưa điền	Chưa điền	Chưa điền
LSTM hai nhánh, có sentiment	Chưa điền	Chưa điền	Chưa điền
TFT, mở rộng	Chưa điền	Chưa điền	Chưa điền

4.4.1. Báo cáo chỉ số theo lớp

Bên cạnh bảng tổng hợp, cần có ma trận nhầm lẫn và precision, recall, F1 của UP, FLAT và DOWN. Phần này cho biết mô hình có dự đoán được lớp ít hay chỉ nghiêng về lớp trung tính. Nếu các mã có phân bố khác nhau, nên báo cáo cả kết quả gộp theo ngày và phân bố theo mã. Không thay thế metric theo lớp bằng một accuracy duy nhất.

4.4.2. Đo phần đóng góp của sentiment

Đóng góp biên được tính bằng hiệu giữa cấu hình có sentiment và price-only trên cùng fold. Bảng báo cáo nên có Δ macro-F1, Δ balanced accuracy và Δ OvR-AUC, cùng khoảng tin cậy bootstrap. Cần chỉ rõ khoảng tin cậy được tính theo ngày, theo mã hay theo block thời gian. Nếu khoảng tin cậy rộng hoặc chênh lệch thay đổi dấu giữa các fold, kết luận phải dùng ngôn ngữ thận trọng như “chưa ổn định”.

Bảng 4.7: Ablation có và không có sentiment, số liệu để điền sau.

So sánh	Δ Macro-F1	Δ Balanced Acc.	Δ OvR-AUC	Khoảng tin cậy
Có sentiment trừ chỉ giá	Chưa điền	Chưa điền	Chưa điền	Chưa điền

4.4.3. Kết quả TFT nếu được thực hiện

TFT chỉ được đưa vào bảng khi mô hình đã được cấu hình cho phân loại ba lớp và chạy trên đúng holdout. Nếu không có số liệu đáng tin cậy, hàng TFT cần được đánh dấu chưa thực hiện thay vì điền bằng kết quả dự kiến.

Variable importance và attention, nếu được báo cáo, phải kèm số mẫu, cửa sổ và caveat rằng đó là diễn giải phụ thuộc mô hình.

4.5. Bàn luận

4.5.1. Bàn luận theo câu hỏi nghiên cứu

Câu hỏi thứ nhất được trả lời bằng chất lượng nhãn, bảng sentiment và phân tích lỗi. Nếu PhoBERT đạt F1 thấp ở lớp nào, cần xem xét các nguyên nhân như lớp thiếu mẫu, tiêu đề mơ hồ, tên thực thể hoặc sự kiện hai chiều. Không được dùng kết quả sentiment của một corpus khác để lấp khoảng trống cho tập hiện tại.

Câu hỏi thứ hai được trả lời bằng bảng thang mô hình và ablation. Nếu LSTM hai nhánh vượt price-only trên nhiều fold với khoảng tin cậy phù hợp, có thể nói sentiment cung cấp dấu hiệu gia tăng trong protocol đã chọn. Nếu cải thiện chỉ xuất hiện ở một số fold, cần báo cáo sự phụ thuộc vào thời kỳ. Nếu không cải thiện, kết luận hợp lệ là chưa có bằng chứng rằng sentiment cải thiện dự báo dưới protocol này.

Câu hỏi thứ ba yêu cầu phân tầng theo coverage tin, volatility hoặc ngày sự kiện. Đây là phân tích bổ sung, không được dùng để chọn một nhóm thuận lợi rồi trình bày như kết quả chung. Các nghiên cứu về sự kiện, quan hệ liên mã và sentiment cho thấy điều kiện thị trường có thể làm thay đổi giá trị của tín hiệu, nhưng các quan sát đó không thay thế cho kiểm tra trên dữ liệu HOSE của đề tài [2], [14], [16].

4.5.2. Kiểm tra tính hợp lệ và độ ổn định

Phần bàn luận cần kiểm tra các điểm sau:

- số fold và số ngày test có đủ để kết luận hay chỉ phù hợp cho mô tả thăm dò;
- chênh lệch có giữ dấu khi đổi seed hoặc cửa sổ hay không;
- ngày không có tin có được xử lý bằng prior và cờ has_news hay không;
- scaler, threshold, imputer và sentiment checkpoint có fit ngoài train không;
- mô hình có sentiment có sử dụng nhiều tham số hơn đáng kể hay không;
- dữ liệu bị loại, mã ít tin và các phiên thiếu có làm lệch kết quả hay không.

Nếu một kiểm tra cho thấy rò rỉ hoặc mapping sai, bảng điểm tương ứng không được dùng để kết luận. Cần sửa pipeline trong phạm vi cho phép, chạy lại đúng protocol và ghi nhận thay đổi. Không sửa holdout, đối metric hoặc lặp nhiều cấu hình mà không log số lần thử.

4.5.3. Giới hạn của thực nghiệm

Giới hạn thứ nhất là dữ liệu chỉ gồm 10 mã và dữ liệu chỉ thuộc HOSE, nên khả năng tổng quát cho HNX, UPCOM hoặc nhóm vốn hóa nhỏ chưa được kiểm tra. Giới hạn thứ hai là timestamp và mapping tin phụ thuộc vào nguồn thu thập; một bản tin thiếu thời điểm có thể phải bị loại. Giới hạn thứ ba là nhãn sentiment chịu ảnh hưởng của hướng dẫn và người gán. Giới hạn thứ tư là dự báo phiên kế tiếp có thể quá ngắn để phản ánh tác động dài hạn của tin.

Ngoài ra, điểm số phân loại không cho biết trực tiếp giá trị kinh tế sau phí giao dịch, trượt giá và giới hạn thanh khoản. Do đó, kết quả của chương này không phải khuyến nghị đầu tư và không được gọi là bằng chứng của một chiến lược giao dịch có lợi nhuận.

Chương 5. KẾT LUẬN

5.1. Tóm tắt nội dung thực hiện

Đồ án đã xác định và mô tả một pipeline dự báo xu hướng biến động giá cổ phiếu trên sàn HOSE, trong đó tin tức tài chính tiếng Việt được xử lý bằng PhoBERT và dữ liệu giá được biểu diễn bằng lợi suất cùng các đặc trưng kỹ thuật. Hai nhánh được căn chỉnh theo mã cổ phiếu, ngày giao dịch và mốc cutoff, sau đó được đưa vào thang mô hình từ baseline đơn giản đến LSTM hai nhánh có fusion. Temporal Fusion Transformer được giữ ở vị trí mở rộng để không làm thay đổi graduation floor.

Quy trình được thiết kế gồm thu thập dữ liệu, kiểm tra provenance và trùng lặp, gán nhãn sentiment, sinh xác suất ba lớp, tổng hợp đặc trưng theo mã và ngày, tạo nhãn UP, FLAT và DOWN, huấn luyện mô hình, đánh giá walk-forward và phân tích ablation. Trong đó, quy tắc train-only preprocessing, cutoff 15 giờ và holdout cuối được khóa là các điều kiện để kết quả dự báo có thể được diễn giải như kết quả ngoài mẫu.

5.2. Đối chiếu với mục tiêu và câu hỏi nghiên cứu

Mục tiêu thứ nhất của đề tài là tạo một bộ dữ liệu có thể truy nguyên. Mức độ hoàn thành mục tiêu này không chỉ được đo bằng số lượng bản ghi, mà còn bằng tỷ lệ có mã, timestamp, nội dung, lịch giá và thông tin nguồn. Các bản ghi không thể xác minh cần được loại hoặc báo cáo riêng.

Mục tiêu thứ hai là đánh giá PhoBERT ở tầng sentiment. Kết luận về tầng này phải dựa trên accuracy, macro-F1, F1 theo lớp và độ đồng thuận nhân của tập in-domain. Chất lượng phân loại sentiment không được đồng nhất với giá trị dự báo, vì một mô hình phân loại tốt vẫn có thể tạo tín hiệu ít liên quan đến biến động phiên kế tiếp. Việc dùng backbone tiếng Việt mở là sự lựa chọn phù hợp với dữ liệu, tương tự cách FinBERT được thích nghi cho ngữ liệu tài chính tiếng Anh, nhưng không phải bằng chứng rằng hai mô hình có hiệu năng tương đương [12], [18].

Mục tiêu thứ ba và thứ tư là kết hợp hai nguồn dữ liệu và huấn luyện mô hình dự báo. Mô hình hai nhánh LSTM là cấu hình sẵn có thể kiểm tra trực tiếp. Cấu hình này kế thừa ý tưởng kết hợp sentiment với LSTM trong các nghiên cứu quốc tế, nhưng thay đổi ngôn ngữ, thị trường, mục tiêu ba lớp và giao thức thời gian [6], [7]. Vì các khác biệt đó, mọi kết luận phải được rút ra từ bảng điểm trên chính dữ liệu HOSE.

Mục tiêu thứ năm là đo phần đóng góp riêng của sentiment. Phép đo phù hợp là chênh lệch giữa mô hình có sentiment và mô hình chỉ giá trên cùng cửa sổ, cùng seed hoặc tập seed, cùng preprocessing và cùng holdout. Nếu chênh lệch nhỏ, không ổn định hoặc không khác biệt rõ, kết quả đó vẫn trả lời được câu hỏi nghiên cứu. Nó cho thấy trong phạm vi protocol hiện tại chưa có bằng chứng đủ mạnh về giá trị gia tăng, chứ không phải phủ định khả năng sentiment hữu ích ở thời điểm hoặc thị trường khác.

5.3. Đóng góp và ý nghĩa

Đóng góp an toàn nhất của đồ án là một quy trình thực nghiệm đa phương thức tiếng Việt được mô tả tường minh. Quy trình này nối một backbone NLP mở với nhánh chuỗi giá, đồng thời đặt phép ablation và kiểm soát point-in-time ở vị trí trung tâm. Đây là điểm cần thiết vì các hướng fusion sử dụng embedding ngữ cảnh, sự kiện hoặc LLM có năng lực biểu đạt cao hơn nhưng cũng tăng yêu cầu về dữ liệu, chi phí và khả năng tái lập [3], [4], [9].

Về phương diện phương pháp, đồ án nhấn mạnh sự phân biệt giữa ba loại kết luận. Loại thứ nhất là kết luận về chất lượng sentiment trên tập được gán nhãn. Loại thứ hai là kết luận về khả năng dự báo ngoài mẫu của từng mô hình. Loại thứ ba là kết luận về phần đóng góp biên của sentiment thông qua ablation. Ba loại kết luận này không được thay thế cho nhau.

Về phương diện thực tiễn, pipeline có thể làm nền cho một công cụ thăm dò dữ liệu, giúp người nghiên cứu xem phân bố tin, xác suất sentiment, trạng thái kỹ thuật và dự đoán lớp theo từng ngày. Tuy nhiên, bản thân pipeline chưa phải hệ thống giao dịch và không cung cấp khuyến nghị đầu tư. Việc đánh giá lợi nhuận sau phí, trượt giá và thanh khoản phải được thực hiện trong một nghiên cứu riêng.

5.4. Giới hạn của đồ án

Thứ nhất, phạm vi chỉ gồm 10 mã VN30 trên HOSE trong giai đoạn 2020 đến quý I năm 2026. Các kết quả có thể chịu ảnh hưởng bởi ngành, thanh khoản và mật độ tin của những mã này. Chưa đủ cơ sở để suy rộng sang cổ phiếu vốn hóa nhỏ, HNX, UPCOM hoặc các thị trường quốc tế.

Thứ hai, dữ liệu tin phụ thuộc vào nguồn, chính sách truy cập và chất lượng timestamp. Bài viết bị thiếu thời gian hoặc được cập nhật nhiều lần có thể làm thay đổi quy tắc ánh xạ. Dù cutoff bảo thủ làm giảm rủi ro dùng tin tương lai, nó cũng có thể làm trễ một phần tín hiệu thực sự được thị trường nhìn thấy trước phiên kế tiếp.

Thứ ba, nhãn sentiment là một khái niệm phụ thuộc vào hướng dẫn và người gán. Một tin chứa nhiều sự kiện có thể vừa tích cực vừa tiêu cực, trong khi nhãn ba lớp buộc phải nén thông tin đó. Độ đồng thuận, phân bố lớp và các mẫu bất đồng cần được công bố để người đọc đánh giá giới hạn này.

Thứ tư, dự báo phiên kế tiếp chỉ quan sát một horizon ngắn. Tin tức về kế hoạch dài hạn, chất lượng quản trị hoặc thay đổi ngành có thể không thể hiện ngay trong lợi suất của phiên sau. Ngoài ra, metric phân loại không phản ánh trực tiếp khả năng sinh lợi. Các nghiên cứu quốc tế dùng mô phỏng giao dịch hoặc mô hình quan hệ liên mã cho thấy đánh giá tài chính có thể cần nhiều góc nhìn hơn accuracy, nhưng những mở rộng đó nằm ngoài graduation floor [3], [17].

5.5. Kết luận cuối cùng

Đề tài cung cấp một cách tiếp cận có kiểm soát để kiểm tra việc bổ sung cảm xúc tin tức tiếng Việt vào dự báo xu hướng giá cổ phiếu. PhoBERT phù hợp làm backbone ngôn ngữ cho dữ liệu tiếng Việt, LSTM hai nhánh phù hợp làm mức sàn cho phép so sánh price-only và có sentiment, còn TFT là hướng mở rộng khi graduation floor đã được xác minh. Giá trị chính của đồ án không nằm ở việc giả định sentiment chắc chắn cải thiện điểm số, mà ở việc xây dựng phép đo có thể phân biệt tín hiệu thực với lợi thế do rò rỉ hoặc do thay đổi protocol.

Kết luận định lượng cuối cùng cần được điền từ bảng kết quả và manifest thực nghiệm ở Chương 4. Dù chênh lệch cuối cùng dương, bằng không hay âm, kết luận phải giữ đúng phạm vi 10 mã, giai đoạn đã chọn và các điều kiện đánh giá. Cách trình bày thận trọng này giúp đồ án có giá trị như một nghiên cứu có thể kiểm tra lại, thay vì đưa ra một lời hứa hiệu năng không có cơ sở ngoài dữ liệu.

Chương 6. HƯỚNG PHÁT TRIỂN

Các hướng phát triển dưới đây được xếp sau graduation floor. Nghĩa là baseline, ablation, walk-forward, kiểm tra cutoff và train-only preprocessing phải được hoàn thiện trước khi thêm mô hình hoặc nguồn dữ liệu mới. Thứ tự này giúp phân biệt cải tiến thực sự với việc tăng độ phức tạp trong khi chưa biết pipeline hiện tại có hợp lệ hay không.

6.1. Củng cố dữ liệu và giao thức point-in-time

Ưu tiên đầu tiên là nâng chất lượng dữ liệu. Có thể mở rộng nguồn tin ngoài Vietstock, nhưng mỗi nguồn mới phải được kiểm tra độ phù hợp theo mã, timestamp, nội dung, trùng lặp, điều khoản truy cập và khả năng tái lập. Một bài viết được đăng lại ở nhiều nguồn cần được nhận diện để không làm tăng giả tạo trọng số của cùng một sự kiện. Các bản ghi bị thiếu thời gian hoặc không xác định được mã nên được loại khỏi tập chính và ghi vào báo cáo coverage.

Mốc cutoff 15 giờ cũng có thể được kiểm tra độ nhạy. Một thực nghiệm riêng có thể so sánh cutoff bảo thủ với một cutoff khác nếu có lý do nghiệp vụ rõ ràng, nhưng mỗi cutoff phải tạo ra feature table và holdout riêng. Không được chọn cutoff dựa trên kết quả test tốt nhất mà không ghi số lần thử. Tương tự, có thể so sánh ngưỡng phân vị với ngưỡng cố định, nhưng cách fit ngưỡng phải tuân thủ train-only trong mọi trường hợp.

Một hướng khác là làm giàu annotation. Tập nhãn có thể bổ sung nhãn cường độ, chủ thể, loại sự kiện và mức độ chắc chắn, nhưng chỉ khi có guideline và đánh giá độ đồng thuận. Nhãn sự kiện fine-grained có tiềm năng bổ sung cho sentiment vì một bài có thể truyền đạt loại sự kiện quan trọng mà phân cực ba lớp không thể hiện [2]. Đây là mở rộng dữ liệu, không được đưa vào so sánh chính nếu làm thay đổi câu hỏi nghiên cứu ban đầu.

6.2. Cơ chế hợp nhất nâng cao

Mức sàn dùng concat vì dễ kiểm tra. Khi dữ liệu đủ lớn, có thể thử gated fusion, trong đó một cổng học cách điều chỉnh mức đóng góp của nhánh sentiment theo trạng thái giá và số tin. Một dạng khác là cross-attention hai chiều, cho phép các bước giá truy vấn chuỗi sentiment và ngược lại. Các mô hình Transformer đa phương thức gợi ý rằng cách hợp nhất động có thể giữ được tương tác giàu hơn concat [4], [13].

Tuy nhiên, fusion động có nhiều tham số hơn và dễ học nhiễu khi chỉ có 10 mã. Mỗi biến thể cần được so sánh với cùng holdout, cùng ngân sách thử và cùng ablation. Cần báo cáo thêm số tham số, thời gian huấn luyện, độ nhạy seed và khoảng tin cậy. Nếu một fusion phức tạp chỉ tốt ở một fold, không nên gọi đó là cải tiến ổn định.

TFT cũng có thể được phát triển thành bộ dự báo đa nhiệm, trong đó một head dự báo lớp xu hướng và một head dự báo volatility hoặc xác suất không có tin. Hướng này chỉ có ý nghĩa nếu loss được cân bằng, nhãn phụ có cơ sở và không làm rò rỉ dữ liệu mục tiêu. Variable importance và attention vẫn phải được diễn giải như tín hiệu nội tại của mô hình, không phải quan hệ nhân quả.

6.3. Mở rộng phạm vi thị trường và concept drift

Sau khi pipeline hoạt động ổn định trên 10 mã, có thể mở rộng sang toàn bộ VN30, HNX, UPCOM hoặc các nhóm ngành khác. Việc mở rộng nên thực hiện theo từng bước, trước hết kiểm tra coverage và tính nhất quán dữ liệu, sau đó đánh giá khả năng tổng quát theo mã. Không gộp mọi mã vào một điểm số duy nhất nếu một số mã có mật độ tin cao hơn nhiều so với phần còn lại.

Các hướng quốc tế như HIST và REST khai thác quan hệ giữa các cổ phiếu, còn DoubleAdapt nhằm đến concept drift trong dữ liệu streaming [16], [17], [19]. Có thể thử một đồ thị ngành hoặc đồ thị được suy ra từ tương quan, nhưng cần làm rõ nguồn quan hệ, thời điểm xây dựng và nguy cơ dùng thông tin tương lai. Đồ thị phải được xây trong train của từng fold nếu nó được học từ dữ liệu. Các hướng MTMD, DishFT-GNN và S³G có thể làm tài liệu tham khảo cho bộ nhớ đa quy mô, distillation và state-space graph, nhưng không phải mục tiêu bắt buộc của đề tài [10], [11], [15].

Một hướng thực tế hơn là kiểm tra concept drift bằng cách huấn luyện trên các cửa sổ khác nhau, theo dõi delta giữa train và test, và cập nhật checkpoint theo lịch khóa. Nếu hệ thống cập nhật online, cần có cơ chế ghi phiên bản dữ liệu, thời điểm cập nhật và rollback. Không nên cập nhật mô hình sau mỗi phiên mà không có đánh giá riêng vì việc đó có thể làm khó phân biệt thích nghi thật với overfitting.

6.4. Đánh giá giá trị kinh tế

Dự báo đúng lớp chưa đủ để kết luận tín hiệu có giá trị giao dịch. Hướng phát triển quan trọng là xây dựng một backtest có quy tắc rõ về thời điểm vào lệnh, giá khớp, phí giao dịch, trượt giá, tỷ trọng, thanh khoản và giới hạn vị thế. Các chỉ số có thể gồm cumulative return, annualized return, Sharpe ratio, maximum drawdown, turnover và ổn định theo giai đoạn.

Backtest phải dùng dự đoán ngoài mẫu theo đúng walk-forward, không dùng dự đoán của holdout để điều chỉnh chiến lược rồi báo cáo lại trên chính holdout. Nếu so sánh nhiều chiến lược, số lần thử cần được ghi và kết luận phải thận trọng trước multiple testing. Các nghiên cứu dùng trading simulation cho thấy đánh giá kinh tế có thể bổ sung cho metric phân loại, nhưng kết quả vẫn phụ thuộc vào giả định mô phỏng và thị trường [3], [5].

Backtest không nằm trong graduation floor vì nó mở rộng câu hỏi từ dự báo sang quyết định giao dịch. Khi được triển khai, cần tách chương trình sinh dự đoán khỏi chương trình mô phỏng, để mọi thay đổi trong chiến lược không làm thay đổi dữ liệu dự báo.

6.5. Giải thích và kiểm tra độ bền

Có thể mở rộng giải thích bằng feature ablation, occlusion, permutation importance, Integrated Gradients cho nhánh văn bản hoặc phân tích các token quan trọng. Mỗi phương pháp có giả định riêng và có thể cho kết quả không giống nhau. Vì vậy, nên xem chúng như bằng chứng bổ sung, đối chiếu với kiểm tra loại biến và báo cáo trường hợp cụ thể.

Phân tích độ bền nên bao gồm thay đổi seed, độ dài cửa sổ, cutoff, ngưỡng nhận và tập mã. Có thể phân tầng theo ngày có sự kiện, số tin, volatility và hướng thị trường. Các nhóm có quá ít quan sát cần được đánh dấu là không đủ để kết luận. Nếu chênh lệch sentiment chỉ xuất hiện khi có nhiều tin, cần kiểm tra xem đó là tín hiệu nội dung hay chỉ là hiệu ứng của cờ has_news và quy mô mẫu.

Một hướng khác là calibration của xác suất. Bên cạnh lớp argmax, có thể đo Brier score, Expected Calibration Error hoặc hiệu chỉnh xác suất trên validation. Điều này hữu ích nếu hệ thống sau này được dùng để xếp hạng mức tin cậy, nhưng không thay thế macro-F1 trong protocol chính.

6.6. Mở rộng mô hình ngôn ngữ

Khi corpus đủ lớn, có thể so sánh PhoBERT-base với các backbone tiếng Việt khác hoặc tiếp tục pretrain trên văn bản tài chính không nhãn. Mọi bước tiếp tục tiền huấn luyện phải lưu phiên bản corpus và kiểm tra không đưa văn bản có nhãn hoặc thông tin tương lai vào quá trình đánh giá. PhoBERT là lựa chọn mở và phù hợp tiếng Việt, nhưng không nên coi checkpoint lớn hơn là mặc nhiên tốt hơn [12].

Có thể thử biểu diễn kết hợp tiêu đề và phần mở đầu, trong đó một encoder xử lý tiêu đề và một encoder xử lý nội dung. Hướng này cần đánh giá riêng ảnh hưởng của độ dài, truncation và bản tin trùng lặp. LLM tài chính như FinGPT hoặc hệ thống hợp nhất qua LLM có thể làm baseline tham khảo, nhưng phải ghi rõ phiên bản, chi phí và khả năng tái lập; chúng không nên thay thế PhoBERT trong pipeline sản [9], [14].

6.7. Đóng gói và tái lập hệ thống

Một phiên bản phát triển hoàn chỉnh nên có các thành phần độc lập: module thu thập, module chuẩn hóa và deduplication, module ánh xạ theo phiên, module suy luận sentiment, module tạo feature table, module huấn luyện, module đánh giá và module trực quan hóa. Các module chia sẻ schema dữ liệu và manifest thay vì đọc các file tạm không có phiên bản.

Hệ thống demo có thể hiển thị dòng tin đã thu thập, xác suất ba lớp, số tin theo mã, đặc trưng kỹ thuật, dự đoán phiên kế tiếp và cảnh báo dữ liệu thiếu. Giao diện chỉ nên trình bày dự đoán cùng thời điểm tạo, checkpoint và độ tin cậy; không gọi đó là khuyến nghị mua bán. Mọi bản ghi demo phải cho biết dữ liệu đến thời điểm nào để người dùng không nhầm giữa kết quả hồi cứu và dự báo thực.

Để tăng khả năng tái lập, cần công bố file cấu hình, seed, hash dữ liệu, phiên bản checkpoint, nhật ký split, số lần thử và cách dựng môi trường. Nếu dữ liệu gốc không thể phân phối do điều khoản nguồn, có thể công bố schema, hash, recipe và một manifest đã ẩn nội dung nhạy cảm, đồng thời mô tả giới hạn truy cập.

6.8. Lộ trình ưu tiên

Lộ trình phát triển được đề xuất như sau:

1. hoàn thiện công chất lượng dữ liệu, cutoff, nhãn và audit leakage;
2. khóa baseline, LSTM hai nhánh, ablation và bootstrap CI trên holdout;
3. kiểm tra độ bền theo seed, cửa sổ, mã và coverage tin;
4. thử TFT classification nếu còn dữ liệu, thời gian và tài nguyên;
5. bổ sung fusion động hoặc event-level signal khi đã có protocol ổn định;
6. mở rộng mã, nguồn và concept drift sau khi đánh giá khả năng tái lập;
7. cuối cùng mới triển khai backtest và các chỉ số giá trị kinh tế.

Thứ tự này bảo vệ mục tiêu cốt lõi của đồ án. Các hướng mở rộng chỉ có ý nghĩa khi chúng được đánh giá trên một nền dữ liệu sạch, có đối chứng và có thể truy nguyên.

TÀI LIỆU THAM KHẢO

- [1] D. Boyle and J. Kalita, “Spatiotemporal Transformer for Stock Movement Prediction,” 2023. arXiv: 2305.03835v1. [Online]. Available: <https://arxiv.org/abs/2305.03835v1>
- [2] D. Chen, Y. Zou, K. Harimoto, R. Bao, X. Ren, and X. Sun, “Incorporating Fine-grained Events in Stock Movement Prediction,” 2019. arXiv: 1910.05078v1. [Online]. Available: <https://arxiv.org/abs/1910.05078v1>
- [3] Q. Chen, “Stock Movement Prediction with Financial News using Contextualized Embedding from BERT,” 2021. arXiv: 2107.08721v1. [Online]. Available: <https://arxiv.org/abs/2107.08721v1>
- [4] A. Elahi and F. Taghvaei, “Combining Financial Data and News Articles for Stock Price Movement Prediction Using Large Language Models,” 2024. arXiv: 2411.01368v1. [Online]. Available: <https://arxiv.org/abs/2411.01368v1>
- [5] F. Feng, H. Chen, X. He, J. Ding, M. Sun, and T.-S. Chua, “Enhancing Stock Movement Prediction with Adversarial Training,” 2018. arXiv: 1810.09936v2. [Online]. Available: <https://arxiv.org/abs/1810.09936v2>
- [6] W. Gu et al., “Predicting Stock Prices with FinBERT-LSTM: Integrating News Sentiment Analysis,” 2024. arXiv: 2407.16150v1. [Online]. Available: <https://arxiv.org/abs/2407.16150v1>
- [7] S. Halder, “FinBERT-LSTM: Deep Learning based stock price prediction using News Sentiment Analysis,” 2022. arXiv: 2211.07392v1. [Online]. Available: <https://arxiv.org/abs/2211.07392v1>
- [8] T. Jiang and Q. Zeng, “Financial sentiment analysis using FinBERT with application in predicting stock movement,” 2023. arXiv: 2306.02136v3. [Online]. Available: <https://arxiv.org/abs/2306.02136v3>
- [9] Y. Liang, Y. Liu, N. Wang, H. Yang, B. Zhang, and C. D. Wang, “FinGPT: Enhancing Sentiment-Based Stock Movement Prediction with Dissemination-Aware and Context-Enriched LLMs,” 2024. arXiv: 2412.10823v2. [Online]. Available: <https://arxiv.org/abs/2412.10823v2>
- [10] Z. Liu, P. Duan, M. Geng, and B. Zhang, “A Distillation-based Future-aware Graph Neural Network for Stock Trend Prediction,” 2025. arXiv: 2502.10776v1. [Online]. Available: <https://arxiv.org/abs/2502.10776v1>
- [11] Y. Lu, K. Hu, and L. Zhang, “S³G: Stock State Space Graph for Enhanced Stock Trend Prediction,” 2026. arXiv: 2603.24236v1. [Online]. Available: <https://arxiv.org/abs/2603.24236v1>
- [12] D. Q. Nguyen and A. T. Nguyen, “PhoBERT: Pre-trained language models for Vietnamese,” 2020. arXiv: 2003.00744v3. [Online]. Available: <https://arxiv.org/abs/2003.00744v3>
- [13] S. Omranpour, G. Rabusseau, and R. Rabbany, “Higher Order Transformers: Enhancing Stock Movement Prediction On Multimodal Time-Series Data,” 2024. arXiv: 2412.10540v1. [Online]. Available: <https://arxiv.org/abs/2412.10540v1>
- [14] W. Siala, A. Khanfir, and M. Papadakis, “Impact of LLMs news Sentiment Analysis on Stock Price Movement Prediction,” 2026. arXiv: 2602.00086v3. [Online]. Available: <https://arxiv.org/abs/2602.00086v3>

- [15] M. Wang, J. Tian, M. Zhang, J. Guo, and W. Jia, “MTMD: Multi-Scale Temporal Memory Learning and Efficient Debiasing Framework for Stock Trend Forecasting,” 2022. arXiv: 2212.08656v2. [Online]. Available: <https://arxiv.org/abs/2212.08656v2>
- [16] W. Xu, W. Liu, C. Xu, J. Bian, J. Yin, and T.-Y. Liu, “REST: Relational Event-driven Stock Trend Forecasting,” 2021. arXiv: 2102.07372v2. [Online]. Available: <https://arxiv.org/abs/2102.07372v2>
- [17] W. Xu et al., “HIST: A Graph-based Framework for Stock Trend Forecasting via Mining Concept-Oriented Shared Information,” 2021. arXiv: 2110.13716v2. [Online]. Available: <https://arxiv.org/abs/2110.13716v2>
- [18] Y. Yang, M. C. S. UY, and A. Huang, “FinBERT: A Pretrained Language Model for Financial Communications,” 2020. arXiv: 2006.08097v2. [Online]. Available: <https://arxiv.org/abs/2006.08097v2>
- [19] L. Zhao, S. Kong, and Y. Shen, “DoubleAdapt: A Meta-learning Approach to Incremental Learning for Stock Trend Forecasting,” 2023. arXiv: 2306.09862v3. [Online]. Available: <https://arxiv.org/abs/2306.09862v3>

Chương A. PHỤ LỤC

A.1. Hướng dẫn gán nhãn cảm xúc in-domain

Trích hướng dẫn gán nhãn ba lớp (NEGATIVE/NEUTRAL/POSITIVE) theo tác động kỳ vọng lên giá, dùng cho tập in-domain và báo cáo kappa.

A.2. Cấu hình tái lập

Liệt kê seed, phiên bản thư viện, và manifest kết quả để tái lập thực nghiệm.

A.3. Mã nguồn

Mã nguồn hệ thống được tổ chức trong package `stf` (repository `stock-trend-forecasting`), gồm các module thu thập dữ liệu, tinh chỉnh cảm xúc và đánh giá.